

Extrapolación de la Fragilización de Aceros de Vasijas Nucleares Usando Redes Neuronales Informadas por la Física (PINNs)

Autor

Samuel Martín Martínez

Profesor/es

Diego Ferreño Blanco

Victor Calzada Cabano

Resumen

Loren Ipsum

Palabras clave: palabra1, palabra2, palabra3, palabra4.

Abstract

Loren Ipsum

Keywords: keyword1, keyword2, keyword3, keyword4.

Índice general

Resumen	2
Abstract	2
1. Introducción (4 páginas max)	5
1.1. Motivación	5
1.2. Problemática	6
1.3. Objetivos	7
2. Estado del Arte (5 páginas max)	9
2.1. Fragilización de Vasijas Nucleares	9
2.2. Modelo Físico Analítico	10
2.3. Machine Learning y PINNs	11
3. Metodología Experimental (17 páginas max)	15
3.1. Descripción y Procesamiento del Dataset	15
3.2. Definición del Baseline Físico	15
3.3. Modelos ML no Informados	15
3.4. Arquitectura del Modelo PINN	15
3.5. Función de Pérdida Personalizada	15
3.6. Optimización de Hiperparámetros	15
4. Resultados y Discusión (8 páginas min)	17
4.1. Comparativa Global de Modelos	17
4.2. Evaluación en Escenarios LTO (Altas Fluencias)	17
4.3. Discusión	17
5. Conclusiones y Trabajo Futuro (3 páginas max)	19

Capítulo 1

Introducción (4 páginas max)

1.1. Motivación

La energía nuclear es fundamental en el mix energético global al aportar estabilidad y generación masiva libre de emisiones. Dado que muchas centrales actuales se aproximan o superan su vida útil de diseño, las demandas energéticas impulsan estrategias de Operación a Largo Plazo (LTO). Sin embargo, la viabilidad de la LTO depende estrictamente de garantizar la integridad estructural de los componentes críticos —frente a fenómenos como la fragilización de la vasija del reactor— durante este periodo de extensión.

En los reactores de agua ligera, la vasija a presión es el componente de seguridad más crítico e insustituible al encargarse de la contención del núcleo. Durante su vida en servicio, la exposición continua a la fluencia neutrónica de la fisión induce daños microestructurales que merman las propiedades mecánicas del acero. Esta fragilización eleva la temperatura de transición del material y reduce su capacidad de absorber energía, un fenómeno cuya magnitud depende de la radiación acumulada y de la composición química original, especialmente de la presencia de cobre, níquel, manganeso y fósforo.

Cuantificar y predecir esta pérdida de tenacidad es vital en el contexto de la LTO, lo que plantea un problema de series temporales y predicción a futuro bajo regímenes de fluencia excepcionalmente altos. Históricamente, este seguimiento se ha realizado mediante correlaciones empíricas como la norma ASTM E900-15, que modela la degradación en función de variables químicas, térmicas y de fluencia. Aunque es una herramienta consolidada, su enfoque determinista puede verse superado por la complejidad y la no linealidad de las interacciones químicas y neutrónicas a gran escala. Por otro lado, los modelos de aprendizaje automático no informados (como XGBoost o Perceptrones Multicapa) destacan al capturar las interacciones no lineales entre las variables metalúrgicas y de fluencia (Liu et al., 2022). Sin embargo, su alta precisión se limita a la interpolación debido a una fuerte dependencia de la densidad de los datos de entrenamiento. Dado que en regímenes de alta fluencia la información experimental es escasa, estos modelos fracasan al extrapolar, asimilando patrones sin rigor que derivan en pronósticos físicamente imposibles sobre la degradación real del material.

Ante la debilidad para extrapolar de los mo-

delos de Machine Learning tradicionales por la falta de datos a altas fluencias y frente a las limitaciones de los modelos puramente analíticos, la motivación de este trabajo se asienta en el desarrollo de un modelo híbrido avanzado. De esta forma, el presente TFM se enfoca en el desarrollo y aplicación de Redes Neuronales Informadas por Física (PINNs, Physics-Informed Neural Networks) (Karniadakis et al., 2021). A diferencia de las aproximaciones clásicas, las PINNs integran el conocimiento fenomenológico a través del modelo analítico (como el descrito por ASTM) directamente en la función de pérdida matemática. De este modo, la red penaliza aquellas predicciones que violen el comportamiento físico subyacente, restringiendo el aprendizaje a soluciones físicamente viables y reales.

1.2. Problemática

La viabilidad de la LTO depende de la gestión del envejecimiento de la Vasija de Presión (RPV), elemento insustituible cuya degradación irreversible limita la vida útil de la central. Bajo la fluencia neutrónica, el acero experimenta alteraciones microestructurales —como la formación de defectos y nano-precipitados— que derivan en la fragilización por irradiación. Este proceso eleva la temperatura de transición (TT_S) y merma la tenacidad a la fractura, estableciendo el desafío técnico fundamental para garantizar la integridad estructural en el marco de la operación extendida.

Esta fragilización no es universal, sino que está íntimamente ligada a la composición química del acero. Elementos traza y de

aleación desempeñan roles determinantes: el cobre (Cu) forma clústeres que bloquean el movimiento de dislocaciones, mientras que el níquel (Ni), manganeso (Mn) y fósforo (P) potencian la formación de fases ricas en solutos que aceleran la degradación (D’Agata et al., 2025). Predecir el comportamiento de una vasija específica requiere un conocimiento preciso de cómo su química interactúa con la temperatura y la dosis acumulada de neutrones.

Históricamente, la industria gestiona este riesgo mediante programas de vigilancia que alimentan modelos analíticos, siendo la norma ASTM E900-15 el estándar predominante. Aunque robusta, esta norma es una simplificación determinista empírica. Al basarse en correlaciones globales, presenta incertidumbres significativas aplicadas a coladas específicas y, por su rigidez, limita su capacidad para asimilar las complejas tendencias de los datos experimentales recientes (Odette et al., 2019).

La integración de Machine Learning (ML), como XGBoost o Perceptrones Multicapa (MLP), ofrece una solución para modelar estas relaciones no lineales sin predefinir funciones. No obstante, el ML “no informado” conlleva un riesgo de extrapolación no física. Validar la LTO requiere predecir el estado de la vasija a altas fluencias neutrónicas, donde los datos experimentales escasean. Un modelo convencional entrenado en este entorno prioriza minimizar el error estadístico; al extrapolar hacia el futuro operativo de la central, tiende a divergir. Así, puede ofrecer resultados matemáticamente óptimos pero físicamente

imposibles —como predecir una recuperación de tenacidad a fluencias extremas—, un error inasumible para la seguridad nuclear.

Esta brecha define el núcleo del problema técnico de este TFM. Ante la escasez de datos a alta fluencia:

- Los modelos analíticos (ASTM) son estables pero inflexibles ante datos complejos.
- El ML tradicional es preciso en interpolación, pero peligrosamente inestable extrapolando para la LTO.
- Subestimar la degradación irreversible podría causar un fallo catastrófico por choque térmico presurizado (PTS).

Por lo tanto, la problemática que este trabajo busca resolver es la creación de un marco predictivo que "sepa" física. Es imperativo utilizar el modelo ASTM como una restricción infranqueable que impida a la red neuronal violar las leyes de degradación donde los datos no pueden guiarla. La integración de Redes Neuronales Informadas por Física (PINNs) surge como respuesta directa (Raissi et al., 2019). Este trabajo aborda el desafío de la LTO mediante la hibridación de conocimiento: suplir la escasez de información futura con el rigor de las ecuaciones analíticas. Uniendo la capacidad de aprendizaje del MLP y el rigor normativo de la ASTM, se garantiza que la predicción de la vida útil de las centrales se asiente sobre una base científicamente coherente y segura.

1.3. Objetivos

El propósito central de este Trabajo de Fin de Máster es el desarrollo, implementación y validación de un modelo predictivo híbrido basado en Redes Neuronales Informadas por la Física (PINNs) para cuantificar la fragilización por irradiación en los aceros de las vasijas de presión de reactores nucleares. Este estudio se enmarca en la necesidad crítica de garantizar la integridad estructural durante la Operación a Largo Plazo (LTO) de las centrales nucleares, donde la capacidad de predicción a altas fluencias —zonas con notable escasez de datos experimentales— resulta determinante para la extensión segura de su vida útil.

Para alcanzar este propósito fundamental, se definen los siguientes objetivos específicos, estructurados según las fases de desarrollo técnico documentadas en la investigación:

- Establecimiento de líneas base analíticas y empíricas: Implementar y evaluar la capacidad predictiva del modelo analítico ASTM E900-15 como referencia física primaria. Este modelo servirá como el estándar sobre el cual se integrará la información en la red neuronal, permitiendo comparar el desempeño de las aproximaciones tradicionales frente a las nuevas técnicas de aprendizaje profundo.
- Desarrollo de modelos de aprendizaje automático no informados: Entrenar y testear algoritmos de Machine Learning convencionales, específicamente XGBoost y Perceptrones Multicapa (MLP), para establecer una base de com-

paración puramente dirigida por datos (data-driven). Este objetivo busca identificar las limitaciones de los modelos estándar cuando se enfrentan a problemas de extrapolación y series temporales con datos escasos.

- Diseño e implementación de la arquitectura PINN: Desarrollar una arquitectura de red neuronal que incorpore términos de penalización en su función de pérdida basados en el modelo analítico ASTM. El objetivo es hibridar la potencia de aprendizaje de las redes neuronales con el rigor del modelo analítico, forzando a la red a respetar las tendencias físicas de la degradación de materiales incluso en ausencia de muestras experimentales.
- Optimización de hiperparámetros mediante búsqueda inteligente: Aplicar técnicas de optimización automatizada (utilizando herramientas como Optuna) para identificar la configuración óptima de la red (número de capas, dimensiones ocultas, tasas de aprendizaje y pesos de la función de pérdida PINN). Se busca asegurar la robustez del modelo frente a la variabilidad de las composiciones químicas de las probetas.
- Validación en escenarios de extrapolación a altas fluencias: Evaluar el rendimiento del modelo híbrido específicamente en regímenes de fluencia neutrónica elevada. Se pretende demostrar que la inclusión de información física permite una generalización superior a la de los modelos ML convencionales, reduciendo el error en la predicción de la temperatu-

ra de transición (TTS) en condiciones de operación extendida.

- Análisis de la influencia de la composición química y la fluencia: Estudiar cómo el modelo asimila la degradación inducida por la interacción entre la fluencia neutrónica y los elementos químicos clave (Cobre, Níquel, Manganeso y Fósforo). Se busca verificar que las predicciones del modelo PINN mantienen coherencia con la fenomenología conocida de la fragilización de aceros ferríticos bajo irradiación.

A través de la consecución de estos objetivos, se pretende proporcionar una herramienta computacional avanzada que complemente los modelos actuales de vigilancia, ofreciendo predicciones de alta fidelidad que faciliten la toma de decisiones estratégicas en el contexto de la gestión del envejecimiento y la seguridad nuclear a largo plazo.

Capítulo 2

Estado del Arte (5 páginas max)

2.1. Fragilización de Vasijas Nucleares

La Vasija de Presión del Reactor (RPV) es, sin duda, el elemento más crítico en la seguridad de cualquier central nuclear de agua ligera. Dado que alberga el núcleo y mantiene el refrigerante a alta presión, funciona como una barrera de contención primaria que resulta materialmente imposible de sustituir. A diferencia de las bombas o las tuberías, que pueden cambiarse o repararse durante las paradas de recarga, la vasija debe aguantar intacta toda la vida útil de la planta. Por eso, mantener su integridad estructural no es solo una cuestión de eficiencia operativa, sino un requisito innegociable de seguridad.

Con el reactor en marcha, el acero ferrítico de la pared interior sufre un bombardeo continuo de neutrones rápidos procedentes de la fisión. Esta exposición, que solemos cuantificar a través de la fluencia neutrónica, acaba provocando daños severos en la microestructura del material. Al chocar con la red cristalina del hierro, los neutrones de alta energía desplazan a los átomos de sus sitios originales, desencadenando cascadas de colisiones y creando pares de Frenkel (vacan-

tes e intersticiales). Con el paso del tiempo y a las elevadas temperaturas de operación, estos defectos se agrupan. Forman así lazos de dislocación y nano-precipitados que, a efectos prácticos, bloquean el movimiento natural de las dislocaciones dentro del metal (Bonny et al., 2013).

El ritmo y la gravedad de este daño no dependen solo de la dosis de radiación que reciba el acero, sino que su composición química de fábrica juega un papel decisivo. Elementos traza como el cobre (Cu) son especialmente problemáticos, ya que tienden a precipitar bajo la irradiación y forman agregados que endurecen muchísimo la matriz férrea. A su vez, el níquel (Ni) y el manganeso (Mn) actúan en sinergia para acelerar estas fases, mientras que el fósforo (P) se acumula en los límites de grano, debilitando la cohesión entre ellos y haciendo que la aleación pierda ductilidad.

A nivel macroscópico, todo este daño interno se traduce en una pérdida evidente de propiedades mecánicas. Lo más preocupante es el aumento del límite elástico, que trae consigo una inevitable caída en la tenacidad a la fractura. En los laboratorios, esto se

ve claramente como un desplazamiento de la curva de energía de impacto hacia temperaturas más altas. Dicho desplazamiento se parametriza mediante la Temperatura de Transición (TTS). Si este valor sube demasiado, corremos el riesgo de que la vasija se vuelva frágil a temperaturas de operación normales o durante enfriamientos bruscos, lo que dispara la probabilidad de un fallo catastrófico por choque térmico presurizado (PTS).

En el contexto actual, alargar la vida útil de las centrales es una estrategia clave para mantener la estabilidad de la red eléctrica. Sin embargo, la fragilización por radiación es el gran cuello de botella. Para que los organismos reguladores aprueben la Operación a Largo Plazo (LTO), hay que demostrar con números que la TTS se mantendrá en niveles seguros, incluso para fluencias neutrónicas que los diseños originales nunca llegaron a contemplar. Acertar con estas predicciones es vital: una estimación demasiado optimista comprometería la seguridad de la planta, mientras que ser excesivamente conservador obligaría a cerrar antes de tiempo instalaciones energéticas perfectamente útiles.

2.2. Modelo Físico Analítico

La gestión del envejecimiento nuclear depende de los programas de vigilancia, donde se insertan cápsulas con probetas del acero original en zonas de alto flujo. Su rotura periódica en ensayos Charpy (CVN) es el estándar para cuantificar la pérdida de tenacidad. A partir de estos datos, la industria ha consolidado bases de datos globales que

permiten predecir el comportamiento de las vasijas mediante la norma ASTM E900-15. Este estándar no es un modelo físico de primeros principios, sino una regresión fenomenológica que estima el desplazamiento de la Temperatura de Transición (ΔTTS) sumando el daño en la matriz (TTS_1) y el de los precipitados (TTS_2):

$$TTS = TTS_1 + TTS_2$$

El daño de matriz (TTS_1) agrupa las dislocaciones y defectos puntuales. Su formulación refleja una dependencia no lineal con la fluencia (Φ) y la química (P, Ni, Mn):

$$TTS_1 = A \cdot \frac{5}{9} \cdot 1,89 \cdot 10^{-12} \cdot \Phi^{0,57} \cdot \left(\frac{1,8T + 32}{550} \right)^{-5,47} \cdot \left(0,09 + \frac{P}{0,012} \right)^{0,22} \cdot \left(1,66 + \frac{Ni^{8,54}}{0,63} \right)^{0,39} \cdot \left(\frac{Mn}{1,36} \right)^{0,3}$$

El término TTS_2 captura el endurecimiento por precipitados de cobre, cuya cinética se satura tras alcanzar cierta fluencia, utilizando funciones de saturación:

$$TTS_2 = \frac{5}{9} \cdot \max [\min(Cu, 0,28) - 0,053, 0] \cdot M$$

Donde M se define mediante las funciones auxiliares de influencia $\mathcal{F}(\Phi)$, $\mathcal{T}(T)$ y $\mathcal{G}(P, Ni)$:

$$M = B \cdot \mathcal{F}(\Phi) \cdot \mathcal{T}(T) \cdot \mathcal{G}(P, Ni) \quad (2.1)$$

Siendo los componentes definidos como:

$$\mathcal{F}(\Phi) = \max \left\{ \min \left[113,87 \ln \left(\frac{\Phi}{4,5 \times 10^{20}} \right), 612 \right], 0 \right\}$$

$$\mathcal{T}(T) = \left(\frac{1,8T + 32}{550} \right)^{-5,45}$$

$$\mathcal{G}(P, Ni) = \left(0,1 + \frac{P}{0,012} \right)^{-0,098} \cdot \left(0,168 + \frac{Ni^{0,58}}{0,63} \right)^{0,73}$$

Este enfoque es robusto y cuenta con la aceptación regulatoria necesaria, pero su validez técnica enfrenta límites infranqueables al proyectar la integridad estructural hacia regímenes de LTO. El modelo ASTM trata la fragilización como un proceso determinista, asumiendo que los coeficientes empíricos —ajustados sobre datos históricos— son universales para cualquier colada. Esta simplificación ignora la heterogeneidad microscópica inherente a los procesos de soldadura y forja, que pueden alterar radicalmente la respuesta del material ante el mismo flujo neutrónico (Eason et al., 2013).

Más crítico aún es el problema de la incertidumbre de extrapolación. Las regresiones de la norma E900-15 se han calibrado principalmente sobre datos de reactores con ciclos de vida de 40 a 50 años. Al intentar aplicar estas correlaciones a 60 u 80 años de operación, el modelo se adentra en un territorio de

fluencias neutrónicas donde la escasez de datos experimentales impide validar la física de los precipitados.

El modelo asume que las funciones de saturación seguirán comportándose de forma monótona, ignorando que a fluencias extremas podrían activarse nuevos mecanismos de degradación microestructural, como la formación de precipitados rutilos o cambios en la fase de solutos que la ASTM no contempla. Al forzar los datos en funciones rígidas de potencia, el modelo ignora posibles transiciones de fase o comportamientos no lineales que surgen exclusivamente en el régimen de operación extendida. Ante este escenario, la comunidad científica ha reconocido que la aproximación analítica tradicional ya no es suficiente; requerimos modelos que no solo se ajusten a los datos, sino que comprendan las restricciones termodinámicas del sistema para evitar proyecciones que, aunque estadísticamente posibles, resulten físicamente inviables.

2.3. Machine Learning y PINNs

En años recientes, la ciencia de materiales nucleares ha virado hacia el uso de Machine Learning (ML). Ante la ingente cantidad de datos de vigilancia, algoritmos como XGBoost y los Perceptrones Multicapa (MLP) han demostrado una capacidad superior para mapear interacciones no lineales que las regresiones paramétricas no logran captar. Mientras que XGBoost destaca por su capacidad de encontrar sinergias químicas mediante ensamblajes de árboles, los MLP utilizan el

Teorema de Aproximación Universal para mapear entradas complejas hacia el valor de TTS . Sin embargo, el valor de estas herramientas en el ámbito nuclear siempre ha sido cuestionado por su naturaleza de ‘‘caja negra’’(*black-box*): la falta de interpretabilidad y de coherencia física es, a menudo, inaceptable para los estándares de seguridad nuclear (Ma et al., 2020).

El desafío real no es la precisión, sino la generalización. Los modelos puramente dirigidos por datos (*data-driven*) presentan una debilidad crítica: el colapso predictivo en la extrapolación. Al entrenarse mediante la minimización del riesgo empírico (ERM), estos modelos ajustan sus pesos buscando reducir el error en el dominio de datos conocido ($\mathcal{D}_{train}$), pero carecen de cualquier mecanismo para validar la coherencia física en el dominio de la Operación a Largo Plazo (LTO). En estos regímenes de alta fluencia, donde los datos experimentales escasean, un modelo convencional tiende a sobreajustarse al ruido estadístico, proyectando trayectorias que, aunque ajustadas matemáticamente, resultan termodinámicamente inviables.

Para solventar esta limitación, la frontera del conocimiento ha integrado leyes fundamentales directamente en la arquitectura mediante las Redes Neuronales Informadas por la Física (PINNs) (Pang et al., 2020). La innovación radica en transformar el entrenamiento de un problema estadístico a uno de optimización restringida. La red no solo minimiza el error frente a las observaciones ($\mathcal{L}_{data}$), sino que es forzada a satisfacer el conocimiento fenomenológico subyacente

mediante un término de penalización física ($\mathcal{L}_{phys}$):

$$\mathcal{L}_{total} = \mathcal{L}_{data} + \lambda_{phys}\mathcal{L}_{phys}$$

El término $\mathcal{L}_{phys}$ actúa como un regularizador matemático severo. Mediante la diferenciación automática (*Autograd*), la PINN evalúa el residuo de las ecuaciones rectoras (como las restricciones de la norma ASTM) sobre la arquitectura de la red en cada iteración. Si la predicción $\hat{y}$ viola la física, el residuo de la función $\mathcal{F}$ diverge:

$$\mathcal{L}_{phys} = \frac{1}{M} \sum_{j=1}^M |\mathcal{F}(\hat{y}_j, \Phi, T, \dots)|^2$$

A diferencia del ML tradicional, donde el espacio de hipótesis es libre, las PINNs restringen el aprendizaje a un subespacio donde las leyes físicas se cumplen. Este *inductive bias* físico es lo que permite que el modelo extrapole con seguridad: al obligar a la red a respetar las asíntotas y las saturaciones de daño conocidas, el modelo no puede divergir hacia comportamientos absurdos.

Esta hibridación representa el marco predictivo definitivo para el envejecimiento nuclear. Combina la expresividad geométrica del *Deep Learning* para el modelado preciso de coladas específicas con la robustez dogmática de las ecuaciones de materiales. El resultado no es simplemente una herramienta de pre-

dicción, sino un modelo que interpola con alta precisión estadística y, de forma crítica, extra-pola bajo el estricto gobierno de la física. Para el análisis de integridad estructural a largo plazo, esta aproximación garantiza proyecciones que son, por diseño, científicamente coherentes y regulatoriamente defendibles.

Capítulo 3

Metodología Experimental (17 páginas max)

Loren Ipsum

3.5. Función de Pérdida Personalizada

3.1. Descripción y Procesamiento del Dataset

Loren Ipsum

Loren Ipsum

3.6. Optimización de Hiperparámetros

3.2. Definición del Baseline Físico

Loren Ipsum

Loren Ipsum

3.3. Modelos ML no Informados

Loren Ipsum

3.4. Arquitectura del Modelo PINN

Loren Ipsum

Capítulo 4

Resultados y Discusión (8 páginas min)

Loren Ipsum

4.1. Comparativa Global de Modelos

Loren Ipsum

4.2. Evaluación en Escenarios LTO (Altas Fluencias)

Loren Ipsum

4.3. Discusión

Loren Ipsum

Capítulo 5

Conclusiones y Trabajo Futuro (3 páginas max)

Loren Ipsum

Bibliografía

- Bonny, G., Terentyev, D., & Bakaev, A. (2013). Ab initio based modelling of dislocation mobility in Fe-Cu alloys. *Journal of Nuclear Materials*, 433, 324-331.
- D'Agata, E., et al. (2025). The LYRA-10 Experiment: Irradiation of Light Water Reactor Pressure Vessel Steels... *Nuclear Science and Engineering*, 1-17.
- Eason, E. D., Odette, G. R., & Nanstad, R. K. (2013). Attenuation of radiation damage in reactor pressure vessel steels. *ASTM Special Technical Publication*, 1559, 1-20.
- Karniadakis, G. E., Kevrekidis, I. G., Lu, L., Perdikaris, P., Wang, S., & Yang, L. (2021). Physics-informed machine learning. *Nature Reviews Physics*, 3(6), 422-440.
- Liu, Y.-c., Wu, H., Mayeshiba, T., Afflerbach, B., Jacobs, R., Perry, J., George, J., Cordell, J., Xia, J., Yuan, H., et al. (2022). Machine learning predictions of irradiation embrittlement in reactor pressure vessel steels. *npj Computational Materials*, 8(1), 85. <https://doi.org/10.1038/s41524-022-00760-4>
- Ma, T., et al. (2020). Deep learning for accelerated discovery of high-entropy alloys. *Materials Today*, 38, 85-93.
- Mathew, J., Parfitt, D., Riddle, N., & Chard-Tuckey, P. (2018). Reactor pressure vessel embrittlement: Insights from neural network modelling. *Journal of Nuclear Materials*, 502, 311-322.
- Odette, G. R., Nanstad, R. K., Server, W. L., & Eason, E. D. (2019). On the history and status of reactor pressure vessel steel ductile to brittle transition temperature shift prediction models. *Journal of Nuclear Materials*, 526, 151863.
- Pang, G., Lu, L., & Karniadakis, G. E. (2020). fPINNs: Fractional physics-informed neural networks. *SIAM Journal on Scientific Computing*, 42(4), A2603-A2630.
- Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378, 686-707.