



Extrapolación de la Fragilización de Aceros de Vasijas Nucleares Usando Redes Neuronales Informadas por la Física (PINNs)

(Extrapolation of the Embrittlement of Nuclear Vessel Steels Using Physics-Informed Neural Networks (PINNs))

Trabajo de Fin de Máster
para acceder al

**MÁSTER EN CIENCIA DE DATOS Y COMPUTACIÓN
AVANZADA**

Autor: Samuel Martín Martínez

Director/es: Diego Ferreño Blanco, Victor Calzada Cabano

Junio - 2026

Resumen

Garantizar la seguridad en la Operación a Largo Plazo (LTO) de las centrales nucleares exige predecir la fragilización de sus vasijas a altas fluencias neutrónicas. Los modelos analíticos tradicionales resultan inflexibles, y el Machine Learning clásico fracasa al extrapolar, arrojando resultados físicamente imposibles. Este Trabajo propone un modelo híbrido mediante Redes Neuronales Informadas por la Física (PINNs), integrando restricciones de monotonía termodinámica en la función de pérdida. Mientras los algoritmos puramente empíricos colapsan al extrapolar ($\text{RMSE} > 64\text{ }^{\circ}\text{C}$), la arquitectura PINN alcanza un RMSE de $16.24\text{ }^{\circ}\text{C}$ y un R^2 de 0.88. Esta solución combina la precisión del Deep Learning con el rigor normativo, permitiendo extrapolaciones seguras y fiables para la gestión del envejecimiento nuclear.

Palabras clave: fragilización por irradiación, Operación a Largo Plazo (LTO), Machine Learning, Redes Neuronales Informadas por la Física (PINN), Vasija de Presión del Reactor (RPV).

Abstract

Ensuring safety in the Long-Term Operation (LTO) of nuclear power plants requires predicting reactor pressure vessel embrittlement at high neutron fluences. Traditional analytical models lack flexibility, and classical Machine Learning fails at extrapolation, yielding physically impossible predictions. This Master's Thesis proposes a hybrid model using Physics-Informed Neural Networks (PINNs), integrating thermodynamic monotonicity constraints directly into the loss function. While purely empirical algorithms collapse during extrapolation ($\text{RMSE} > 64\text{ }^{\circ}\text{C}$), the PINN architecture achieves an RMSE of $16.24\text{ }^{\circ}\text{C}$ and an R^2 of 0.88. This solution successfully combines the accuracy of Deep Learning with regulatory rigor, enabling safe and reliable extrapolations for nuclear aging management.

Keywords: radiation embrittlement, Long-Term Operation (LTO), Machine Learning, Physics-Informed Neural Networks (PINN), Reactor Pressure Vessel (RPV).

Índice general

Resumen	2
Abstract	2
1. Introducción	5
1.1. Motivación	5
1.2. Problemática	6
1.3. Objetivos	7
2. Estado del Arte	9
2.1. Fragilización de Vasijas Nucleares	9
2.2. Modelo Físico Analítico	10
2.3. Machine Learning y PINNs	11
3. Metodología Experimental	15
3.1. Descripción y Procesamiento del Dataset	15
3.1.1. Ingesta y Naturaleza de los Datos	15
3.1.2. Preprocesamiento y Transformación de Variables	16
3.1.3. Estrategia de Partición (Data Splitting)	16
3.1.4. Normalización y Prevención de Fuga de Información	17
3.1.5. Transformación Inversa de Predicciones	17
3.2. Definición del Baseline Físico	18
3.3. Modelos ML no Informados	19
3.3.1. Modelo de Ensamblaje: XGBoost	20
3.3.2. Aprendizaje Profundo: Perceptrón Multicapa (MLP Inicial)	20
3.3.3. Minimización del Riesgo Empírico y Justificación Metodológica	21
3.4. Arquitectura del Modelo PINN	22
3.4.1. Diseño Topológico y Dinámico	22
3.4.2. Flujo Tensorial y Estrategia de Aprendizaje Residual	23
3.4.3. Motor de Diferenciación Automática (Autograd)	23
3.4.4. Entorno Computacional y Aceleración de Hardware	24
3.5. Función de Pérdida Personalizada	24
3.5.1. Formulación Matemática de la Pérdida Combinada	25

3.5.2.	La Restricción Física: Monotonía respecto a la Fluencia	25
3.5.3.	Algoritmo y Penalización Diferencial Continua	26
3.5.4.	Justificación Metodológica y Generalización	27
3.6.	Optimización de Hiperparámetros	27
3.6.1.	Justificación de la Búsqueda Bayesiana	27
3.6.2.	Definición del Espacio de Búsqueda Paramétrico	28
3.6.3.	Estrategia de Validación y Función Objetivo	29
3.6.4.	Gestión de Memoria y Aceleración en VRAM	29
4.	Resultados y Discusión	31
4.1.	Comparativa Global de Modelos	31
4.2.	Evaluación en Escenarios LTO (Altas Fluencias)	32
4.3.	Discusión	33
5.	Conclusiones y Trabajo Futuro	35

Capítulo 1

Introducción

1.1. Motivación

La energía nuclear es fundamental en el mix energético global al aportar estabilidad y generación masiva libre de emisiones. Dado que muchas centrales actuales se aproximan o superan su vida útil de diseño, las demandas energéticas impulsan estrategias de Operación a Largo Plazo (LTO). Sin embargo, la viabilidad de la LTO depende estrictamente de garantizar la integridad estructural de los componentes críticos —frente a fenómenos como la fragilización de la vasija del reactor— durante este periodo de extensión.

En los reactores de agua ligera, la vasija a presión es el componente de seguridad más crítico e insustituible al encargarse de la contención del núcleo. Durante su vida en servicio, la exposición continua a la fluencia neutrónica de la fisión induce daños microestructurales que merman las propiedades mecánicas del acero. Esta fragilización eleva la temperatura de transición del material y reduce su capacidad de absorber energía, un fenómeno cuya magnitud depende de la radiación acumulada y de la composición química original, especialmente de la presencia de cobre, níquel, manganeso y fósforo.

Cuantificar y predecir esta pérdida de tenacidad es vital en el contexto de la LTO, lo que plantea un problema de series temporales y predicción a futuro bajo regímenes de fluencia excepcionalmente altos. Históricamente, este seguimiento se ha realizado mediante correlaciones empíricas como la norma ASTM E900-15, que modela la degradación en función de variables químicas, térmicas y de fluencia. Aunque es una herramienta consolidada, su enfoque determinista puede verse superado por la complejidad y la no linealidad de las interacciones químicas y neutrónicas a gran escala. Por otro lado, los modelos de aprendizaje automático no informados (como XGBoost o Perceptrones Multicapa) destacan al capturar las interacciones no lineales entre las variables metalúrgicas y de fluencia (Liu et al., 2022). Sin embargo, su alta precisión se limita a la interpolación debido a una fuerte dependencia de la densidad de los datos de entrenamiento. Dado que en regímenes de alta fluencia la información experimental es escasa, estos modelos fracasan al extrapolar, asimilando patrones sin rigor que derivan en pronósticos físicamente imposibles sobre la degradación real del material.

Ante la debilidad para extrapolar de los modelos de Machine Learning tradicionales por

la falta de datos a altas fluencias y frente a las limitaciones de los modelos puramente analíticos, la motivación de este trabajo se asienta en el desarrollo de un modelo híbrido avanzado. De esta forma, el presente TFM se enfoca en el desarrollo y aplicación de Redes Neuronales Informadas por Física (PINNs, Physics-Informed Neural Networks) (Karniadakis et al., 2021). A diferencia de las aproximaciones clásicas, las PINNs integran el conocimiento fenomenológico a través del modelo analítico (como el descrito por ASTM) directamente en la función de pérdida matemática. De este modo, la red penaliza aquellas predicciones que violen el comportamiento físico subyacente, restringiendo el aprendizaje a soluciones físicamente viables y reales.

1.2. Problemática

La viabilidad de la LTO depende de la gestión del envejecimiento de la Vasija de Presión (RPV), elemento insustituible cuya degradación irreversible limita la vida útil de la central. Bajo la fluencia neutrónica, el acero experimenta alteraciones microestructurales —como la formación de defectos y nano-precipitados— que derivan en la fragilización por irradiación. Este proceso eleva la temperatura de transición (TTS) y merma la tenacidad a la fractura, estableciendo el desafío técnico fundamental para garantizar la integridad estructural en el marco de la operación extendida.

Esta fragilización no es universal, sino que está íntimamente ligada a la composición química del acero. Elementos traza y de aleación desempeñan roles determinantes: el

cobre (Cu) forma clústeres que bloquean el movimiento de dislocaciones, mientras que el níquel (Ni), manganeso (Mn) y fósforo (P) potencian la formación de fases ricas en solutos que aceleran la degradación (D’Agata et al., 2025). Predecir el comportamiento de una vasija específica requiere un conocimiento preciso de cómo su química interactúa con la temperatura y la dosis acumulada de neutrones.

Históricamente, la industria gestiona este riesgo mediante programas de vigilancia que alimentan modelos analíticos, siendo la norma ASTM E900-15 el estándar predominante. Aunque robusta, esta norma es una simplificación determinista empírica. Al basarse en correlaciones globales, presenta incertidumbres significativas aplicadas a coladas específicas y, por su rigidez, limita su capacidad para asimilar las complejas tendencias de los datos experimentales recientes (Odette et al., 2019).

La integración de Machine Learning (ML), como XGBoost o Perceptrones Multicapa (MLP), ofrece una solución para modelar estas relaciones no lineales sin predefinir funciones. No obstante, el ML “no informado” conlleva un riesgo de extrapolación no física. Validar la LTO requiere predecir el estado de la vasija a altas fluencias neutrónicas, donde los datos experimentales escasean. Un modelo convencional entrenado en este entorno prioriza minimizar el error estadístico; al extrapolar hacia el futuro operativo de la central, tiende a divergir. Así, puede ofrecer resultados matemáticamente óptimos pero físicamente imposibles —como predecir una recuperación

de tenacidad a fluencias extremas—, un error inasumible para la seguridad nuclear.

Esta brecha define el núcleo del problema técnico de este TFM. Ante la escasez de datos a alta fluencia:

- Los modelos analíticos (ASTM) son estables pero inflexibles ante datos complejos.
- El ML tradicional es preciso en interpolación, pero peligrosamente inestable extrapolando para la LTO.
- Subestimar la degradación irreversible podría causar un fallo catastrófico por choque térmico presurizado (PTS).

Por lo tanto, la problemática que este trabajo busca resolver es la creación de un marco predictivo que "sepa" física. Es imperativo utilizar el modelo ASTM como una restricción infranqueable que impida a la red neuronal violar las leyes de degradación donde los datos no pueden guiarla. La integración de Redes Neuronales Informadas por Física (PINNs) surge como respuesta directa (Raissi et al., 2019). Este trabajo aborda el desafío de la LTO mediante la hibridación de conocimiento: suplir la escasez de información futura con el rigor de las ecuaciones analíticas. Uniendo la capacidad de aprendizaje del MLP y el rigor normativo de la ASTM, se garantiza que la predicción de la vida útil de las centrales se asiente sobre una base científicamente coherente y segura.

1.3. Objetivos

El propósito central de este Trabajo de Fin de Máster es el desarrollo, implementación y

validación de un modelo predictivo híbrido basado en Redes Neuronales Informadas por la Física (PINNs) para cuantificar la fragilización por irradiación en los aceros de las vasijas de presión de reactores nucleares. Este estudio se enmarca en la necesidad crítica de garantizar la integridad estructural durante la Operación a Largo Plazo (LTO) de las centrales nucleares, donde la capacidad de predicción a altas fluencias —zonas con notable escasez de datos experimentales— resulta determinante para la extensión segura de su vida útil.

Para alcanzar este propósito fundamental, se definen los siguientes objetivos específicos, estructurados según las fases de desarrollo técnico documentadas en la investigación:

- Establecimiento de líneas base analíticas y empíricas: Implementar y evaluar la capacidad predictiva del modelo analítico ASTM E900-15 como referencia física primaria. Este modelo servirá como el estándar sobre el cual se integrará la información en la red neuronal, permitiendo comparar el desempeño de las aproximaciones tradicionales frente a las nuevas técnicas de aprendizaje profundo.
- Desarrollo de modelos de aprendizaje automático no informados: Entrenar y testear algoritmos de Machine Learning convencionales, específicamente XGBoost y Perceptrones Multicapa (MLP), para establecer una base de comparación puramente dirigida por datos (data-driven). Este objetivo busca identificar las limitaciones de los modelos estándar cuando se enfrentan a problemas

de extrapolación y series temporales con datos escasos.

- **Diseño e implementación de la arquitectura PINN:** Desarrollar una arquitectura de red neuronal que incorpore términos de penalización en su función de pérdida basados en el modelo analítico ASTM. El objetivo es hibridar la potencia de aprendizaje de las redes neuronales con el rigor del modelo analítico, forzando a la red a respetar las tendencias físicas de la degradación de materiales incluso en ausencia de muestras experimentales.
- **Optimización de hiperparámetros mediante búsqueda inteligente:** Aplicar técnicas de optimización automatizada (utilizando herramientas como Optuna) para identificar la configuración óptima de la red (número de capas, dimensiones ocultas, tasas de aprendizaje y pesos de la función de pérdida PINN). Se busca asegurar la robustez del modelo frente a la variabilidad de las composiciones químicas de las probetas.
- **Validación en escenarios de extrapolación a altas fluencias:** Evaluar el rendimiento del modelo híbrido específicamente en regímenes de fluencia neutrónica elevada. Se pretende demostrar que la inclusión de información física permite una generalización superior a la de los modelos ML convencionales, reduciendo el error en la predicción de la temperatura de transición (TTS) en condiciones de operación extendida.
- **Análisis de la influencia de la composición química y la fluencia:** Estudiar cómo

el modelo asimila la degradación inducida por la interacción entre la fluencia neutrónica y los elementos químicos clave (Cobre, Níquel, Manganeso y Fósforo). Se busca verificar que las predicciones del modelo PINN mantienen coherencia con la fenomenología conocida de la fragilización de aceros ferríticos bajo irradiación.

A través de la consecución de estos objetivos, se pretende proporcionar una herramienta computacional avanzada que complemente los modelos actuales de vigilancia, ofreciendo predicciones de alta fidelidad que faciliten la toma de decisiones estratégicas en el contexto de la gestión del envejecimiento y la seguridad nuclear a largo plazo.

Capítulo 2

Estado del Arte

2.1. Fragilización de Vasijas Nucleares

La Vasija de Presión del Reactor (RPV) es, sin duda, el elemento más crítico en la seguridad de cualquier central nuclear de agua ligera. Dado que alberga el núcleo y mantiene el refrigerante a alta presión, funciona como una barrera de contención primaria que resulta materialmente imposible de sustituir. A diferencia de las bombas o las tuberías, que pueden cambiarse o repararse durante las paradas de recarga, la vasija debe aguantar intacta toda la vida útil de la planta. Por eso, mantener su integridad estructural no es solo una cuestión de eficiencia operativa, sino un requisito innegociable de seguridad.

Con el reactor en marcha, el acero ferrítico de la pared interior sufre un bombardeo continuo de neutrones rápidos procedentes de la fisión. Esta exposición, que solemos cuantificar a través de la fluencia neutrónica, acaba provocando daños severos en la microestructura del material. Al chocar con la red cristalina del hierro, los neutrones de alta energía desplazan a los átomos de sus sitios originales, desencadenando cascadas de colisiones y creando pares de Frenkel (vacan-

tes e intersticiales). Con el paso del tiempo y a las elevadas temperaturas de operación, estos defectos se agrupan. Forman así lazos de dislocación y nano-precipitados que, a efectos prácticos, bloquean el movimiento natural de las dislocaciones dentro del metal (Bonny et al., 2013).

El ritmo y la gravedad de este daño no dependen solo de la dosis de radiación que reciba el acero, sino que su composición química de fábrica juega un papel decisivo. Elementos traza como el cobre (Cu) son especialmente problemáticos, ya que tienden a precipitar bajo la irradiación y forman agregados que endurecen muchísimo la matriz férrica. A su vez, el níquel (Ni) y el manganeso (Mn) actúan en sinergia para acelerar estas fases, mientras que el fósforo (P) se acumula en los límites de grano, debilitando la cohesión entre ellos y haciendo que la aleación pierda ductilidad.

A nivel macroscópico, todo este daño interno se traduce en una pérdida evidente de propiedades mecánicas. Lo más preocupante es el aumento del límite elástico, que trae consigo una inevitable caída en la tenacidad a la fractura. En los laboratorios, esto se ve claramente como un desplazamiento de

la curva de energía de impacto hacia temperaturas más altas. Dicho desplazamiento se parametriza mediante la Temperatura de Transición (TTS). Si este valor sube demasiado, corremos el riesgo de que la vasija se vuelva frágil a temperaturas de operación normales o durante enfriamientos bruscos, lo que dispara la probabilidad de un fallo catastrófico por choque térmico presurizado (PTS).

En el contexto actual, alargar la vida útil de las centrales es una estrategia clave para mantener la estabilidad de la red eléctrica. Sin embargo, la fragilización por radiación es el gran cuello de botella. Para que los organismos reguladores aprueben la Operación a Largo Plazo (LTO), hay que demostrar con números que la TTS se mantendrá en niveles seguros, incluso para fluencias neutrónicas que los diseños originales nunca llegaron a contemplar. Acertar con estas predicciones es vital: una estimación demasiado optimista comprometería la seguridad de la planta, mientras que ser excesivamente conservador obligaría a cerrar antes de tiempo instalaciones energéticas perfectamente útiles.

2.2. Modelo Físico Analítico

La gestión del envejecimiento nuclear depende de los programas de vigilancia, donde se insertan cápsulas con probetas del acero original en zonas de alto flujo. Su rotura periódica en ensayos Charpy (CVN) es el estándar para cuantificar la pérdida de tenacidad. A partir de estos datos, la industria ha consolidado bases de datos globales que permiten predecir el comportamiento de las

vasijas mediante la norma ASTM E900-15. Este estándar no es un modelo físico de primeros principios, sino una regresión fenomenológica que estima el desplazamiento de la Temperatura de Transición (ΔTTS) sumando el daño en la matriz (TTS_1) y el de los precipitados (TTS_2):

$$TTS = TTS_1 + TTS_2$$

El daño de matriz (TTS_1) agrupa las dislocaciones y defectos puntuales. Su formulación refleja una dependencia no lineal con la fluencia (Φ) y la química (P, Ni, Mn):

$$TTS_1 = A \cdot \frac{5}{9} \cdot 1,89 \cdot 10^{-12} \cdot \Phi^{0,57} \cdot \left(\frac{1,8T + 32}{550} \right)^{-5,47} \cdot \left(0,09 + \frac{P}{0,012} \right)^{0,22} \cdot \left(1,66 + \frac{Ni^{8,54}}{0,63} \right)^{0,39} \cdot \left(\frac{Mn}{1,36} \right)^{0,3}$$

El término TTS_2 captura el endurecimiento por precipitados de cobre, cuya cinética se satura tras alcanzar cierta fluencia, utilizando funciones de saturación:

$$TTS_2 = \frac{5}{9} \cdot \max [\min(Cu, 0,28) - 0,053, 0] \cdot M$$

Donde M se define mediante las funciones auxiliares de influencia $\mathcal{F}(\Phi)$, $\mathcal{T}(T)$ y $\mathcal{G}(P, Ni)$:

$$M = B \cdot \mathcal{F}(\Phi) \cdot \mathcal{T}(T) \cdot \mathcal{G}(P, Ni) \quad (2.1)$$

Siendo los componentes definidos como:

$$\mathcal{F}(\Phi) = \max \left\{ \min \left[113,87 \ln \left(\frac{\Phi}{4,5 \times 10^{20}} \right), 612 \right], 0 \right\}$$

$$\mathcal{T}(T) = \left(\frac{1,8T + 32}{550} \right)^{-5,45}$$

$$\mathcal{G}(P, Ni) = \left(0,1 + \frac{P}{0,012} \right)^{-0,098} \cdot \left(0,168 + \frac{Ni^{0,58}}{0,63} \right)^{0,73}$$

Este enfoque es robusto y cuenta con la aceptación regulatoria necesaria, pero su validez técnica enfrenta límites infranqueables al proyectar la integridad estructural hacia regímenes de LTO. El modelo ASTM trata la fragilización como un proceso determinista, asumiendo que los coeficientes empíricos —ajustados sobre datos históricos— son universales para cualquier colada. Esta simplificación ignora la heterogeneidad microscópica inherente a los procesos de soldadura y forja, que pueden alterar radicalmente la respuesta del material ante el mismo flujo neutrónico (Eason et al., 2013).

Más crítico aún es el problema de la incertidumbre de extrapolación. Las regresiones de la norma E900-15 se han calibrado principalmente sobre datos de reactores con ciclos de vida de 40 a 50 años. Al intentar aplicar estas correlaciones a 60 u 80 años de operación, el modelo se adentra en un territorio de fluencias neutrónicas donde la escasez de

datos experimentales impide validar la física de los precipitados.

El modelo asume que las funciones de saturación seguirán comportándose de forma monótona, ignorando que a fluencias extremas podrían activarse nuevos mecanismos de degradación microestructural, como la formación de precipitados rutilos o cambios en la fase de solutos que la ASTM no contempla. Al forzar los datos en funciones rígidas de potencia, el modelo ignora posibles transiciones de fase o comportamientos no lineales que surgen exclusivamente en el régimen de operación extendida. Ante este escenario, la comunidad científica ha reconocido que la aproximación analítica tradicional ya no es suficiente; requerimos modelos que no solo se ajusten a los datos, sino que comprendan las restricciones termodinámicas del sistema para evitar proyecciones que, aunque estadísticamente posibles, resulten físicamente inviables.

2.3. Machine Learning y PINNs

En años recientes, la ciencia de materiales nucleares ha virado hacia el uso de Machine Learning (ML). Ante la ingente cantidad de datos de vigilancia, algoritmos como XGBoost y los Perceptrones Multicapa (MLP) han demostrado una capacidad superior para mapear interacciones no lineales que las regresiones paramétricas no logran captar. Mientras que XGBoost destaca por su capacidad de encontrar sinergias químicas mediante ensamblajes de árboles, los MLP utilizan el Teorema de Aproximación Universal para

mapear entradas complejas hacia el valor de TTS . Sin embargo, el valor de estas herramientas en el ámbito nuclear siempre ha sido cuestionado por su naturaleza de ‘caja negra’ (*black-box*): la falta de interpretabilidad y de coherencia física es, a menudo, inaceptable para los estándares de seguridad nuclear (Ma et al., 2020).

El desafío real no es la precisión, sino la generalización. Los modelos puramente dirigidos por datos (*data-driven*) presentan una debilidad crítica: el colapso predictivo en la extrapolación. Al entrenarse mediante la minimización del riesgo empírico (ERM), estos modelos ajustan sus pesos buscando reducir el error en el dominio de datos conocido ($\mathcal{D}_{train}$), pero carecen de cualquier mecanismo para validar la coherencia física en el dominio de la Operación a Largo Plazo (LTO). En estos regímenes de alta fluencia, donde los datos experimentales escasean, un modelo convencional tiende a sobreajustarse al ruido estadístico, proyectando trayectorias que, aunque ajustadas matemáticamente, resultan termodinámicamente inviables.

Para solventar esta limitación, la frontera del conocimiento ha integrado leyes fundamentales directamente en la arquitectura mediante las Redes Neuronales Informadas por la Física (PINNs) (Pang et al., 2020). La innovación radica en transformar el entrenamiento de un problema estadístico a uno de optimización restringida. La red no solo minimiza el error frente a las observaciones ($\mathcal{L}_{data}$), sino que es forzada a satisfacer el conocimiento fenomenológico subyacente mediante un término de penalización física

($\mathcal{L}_{phys}$):

$$\mathcal{L}_{total} = \mathcal{L}_{data} + \lambda_{phys} \mathcal{L}_{phys}$$

El término $\mathcal{L}_{phys}$ actúa como un regularizador matemático severo. Mediante la diferenciación automática (*Autograd*), la PINN evalúa el residuo de las ecuaciones rectoras (como las restricciones de la norma ASTM) sobre la arquitectura de la red en cada iteración. Si la predicción $\hat{y}$ viola la física, el residuo de la función $\mathcal{F}$ diverge:

$$\mathcal{L}_{phys} = \frac{1}{M} \sum_{j=1}^M |\mathcal{F}(\hat{y}_j, \Phi, T, \dots)|^2$$

A diferencia del ML tradicional, donde el espacio de hipótesis es libre, las PINNs restringen el aprendizaje a un subespacio donde las leyes físicas se cumplen. Este *inductive bias* físico es lo que permite que el modelo extrapole con seguridad: al obligar a la red a respetar las asíntotas y las saturaciones de daño conocidas, el modelo no puede divergir hacia comportamientos absurdos.

Esta hibridación representa el marco predictivo definitivo para el envejecimiento nuclear. Combina la expresividad geométrica del *Deep Learning* para el modelado preciso de coladas específicas con la robustez dogmática de las ecuaciones de materiales. El resultado no es simplemente una herramienta de predicción, sino un modelo que interpola con alta

precisión estadística y, de forma crítica, extrapola bajo el estricto gobierno de la física. Para el análisis de integridad estructural a largo plazo, esta aproximación garantiza proyecciones que son, por diseño, científicamente coherentes y regulatoriamente defendibles.

Capítulo 3

Metodología Experimental

3.1. Descripción y Procesamiento del Dataset

El desarrollo de cualquier modelo computacional de aprendizaje automático y, en particular, de las Redes Neuronales Informadas por la Física (PINNs), exige como paso fundamental una rigurosa ingesta, exploración y adecuación de los datos. En este trabajo, la base de datos experimental constituye el pilar sobre el cual se asientan tanto el aprendizaje empírico de los algoritmos como la validación del modelo físico de referencia. Para gestionar este flujo de trabajo de manera estructurada, modular y compatible con el ecosistema de *Deep Learning*, se ha diseñado e implementado la clase orientada a objetos `RadiationDataset`, la cual hereda directamente de la clase `Dataset` de la librería `PyTorch`. Esta arquitectura de software permite una manipulación eficiente de los tensores durante el entrenamiento.

3.1.1. Ingesta y Naturaleza de los Datos

El corpus de datos original se encuentra almacenado en formato de valores separados por comas (CSV). La ingesta inicial de esta in-

formación se ha implementado mediante la librería `Pandas`, una herramienta estándar en la industria científica que permite la carga y manipulación tabular de grandes volúmenes de información estructurada. El conjunto de datos recopilado e integrado en este estudio consta de un total de 1889 muestras independientes, las cuales representan ensayos reales sobre aceros de vasijas de reactores nucleares.

Cada una de estas observaciones está caracterizada por 8 variables fundamentales que capturan tanto el entorno radiológico como la naturaleza metalúrgica del material. Metodológicamente, estas variables se dividen en una variable objetivo (dependiente) y siete variables predictoras (independientes).

La variable objetivo a predecir es el desplazamiento de la temperatura de transición, denotada en el dataset como `DT41J_Celsius`. Esta magnitud térmica cuantifica el grado de fragilización por irradiación que ha sufrido la probeta, constituyendo la métrica de daño estructural que el modelo debe aprender a inferir.

Por otro lado, las variables independientes actúan como los descriptores del problema físico. Éstas incluyen:

- **Fluencia neutrónica (Φ):** Representa la dosis acumulada de radiación recibida por el material, siendo el principal motor

del daño microestructural.

- **Temperatura de irradiación (T):** La temperatura ambiente a la que el acero ha estado expuesto durante el ciclo de vida operativo en el reactor.
- **Composición química:** Cuatro variables continuas que detallan el porcentaje en peso de los elementos aleantes y traza más determinantes en la sinergia de la fragilización: Cobre (Cu), Níquel (Ni), Manganeso (Mn) y Fósforo (P).
- **Tipo de producto (Product Form):** Una variable categórica que indica el origen del proceso de manufactura del acero, clasificado habitualmente como Forja ('F'), Placa ('P') o Soldadura ('W').

3.1.2. Preprocesamiento y Transformación de Variables

Los algoritmos de aprendizaje automático, por su fundamentación matemática basada en el cálculo matricial y la optimización de gradientes, requieren que todos los tensores de entrada posean una naturaleza estrictamente numérica. Por consiguiente, el primer paso del preprocesamiento metodológico ha consistido en la transformación de la variable categórica `Product_Form`. En el constructor de la clase `RadiationDataset`, se ha implementado una rutina que detecta esta columna y aplica una conversión mediante los métodos `astype('category').cat.codes` de Pandas. Esta operación mapea internamente las cadenas de texto ('F', 'P', 'W') a códigos enteros discretos (por ejemplo, 0, 1 y 2), preservando la información del proceso de fa-

bricación en un formato algebraicamente operable por la red neuronal.




Figura 3.1: Matriz de correlación entre las variables del dataset. Se observa una fuerte correlación positiva entre la fluencia neutrónica (Φ) y el desplazamiento de la temperatura de transición (DT41J_Celsius), lo que es consistente con la física del problema.

3.1.3. Estrategia de Partición (Data Splitting)

Para garantizar la validez científica de los resultados y evaluar la verdadera capacidad de generalización del modelo frente a datos no observados, se ha implementado el método `data_split`. Este método fragmenta el corpus total de 1889 muestras en tres subconjuntos disjuntos: Entrenamiento (*Train*), Validación (*Validation*) y Prueba (*Test*).

El conjunto de entrenamiento se emplea exclusivamente para la actualización de los pesos sinápticos mediante retropropagación. El conjunto de validación actúa como un entorno de prueba intermedio, fundamental para detener el entrenamiento prematuramente (*Early Stop-*

ping) si se detecta sobreajuste y para guiar la búsqueda de hiperparámetros. Finalmente, se ha reservado un conjunto de prueba puro (típicamente el 20 % de los datos) que permanece estrictamente oculto durante toda la fase de optimización, asegurando que las métricas finales reportadas (como el RMSE) reflejen un rendimiento realista ante futuras aplicaciones en la Operación a Largo Plazo (LTO).

3.1.4. Normalización y Prevención de Fuga de Información

Uno de los aspectos más críticos en el modelado de redes neuronales es el tratamiento de la escala de las variables. En el problema físico que nos ocupa, las magnitudes de entrada son inherentemente dispares: mientras que la fluencia neutrónica (Φ) maneja órdenes de magnitud extremadamente elevados (típicamente en el rango de 10^{19} a 10^{20} n/cm^2), variables químicas como el contenido de fósforo (P) presentan valores minúsculos (del orden de 0,01 %). Si estos datos crudos se inyectasen directamente en un Perceptrón Multicapa, las variables con mayores magnitudes numéricas dominarían artificialmente el cálculo del gradiente durante el algoritmo de *Backpropagation*, provocando inestabilidades numéricas, oscilaciones en la función de pérdida y convergencias subóptimas.

Para mitigar este fenómeno, se ha implementado un escalado estándar (*Z-score normalization*) utilizando la clase `StandardScaler` de la librería `Scikit-Learn`. Esta transformación re-centra cada característica matemática para que posea una media de cero ($\mu = 0$) y una varianza unitaria ($\sigma = 1$), de acuerdo con la expresión:

$$z = \frac{x - \mu}{\sigma} \quad (3.1)$$

Es metodológicamente imperativo destacar que el cálculo de los parámetros estadísticos de normalización (la media μ y la desviación estándar σ) se realiza **exclusiva y estrictamente** sobre el conjunto de entrenamiento (mediante el método `fit`). Posteriormente, estos mismos parámetros estáticos se utilizan para transformar (`transform`) los conjuntos de validación y prueba. Si el escalado se hubiese ajustado sobre la totalidad del dataset antes de la partición, se habría incurrido en un grave error metodológico conocido como "fuga de información" (*data leakage*). La fuga de información ocurre cuando información estadística del conjunto de prueba contamina el conjunto de entrenamiento, dotando al modelo de una ventaja artificial e invalidando la integridad de los resultados predictivos.

3.1.5. Transformación Inversa de Predicciones

Dado que la variable objetivo `DT41J_Celsius` también se normaliza para estabilizar la convergencia de la red neuronal, las salidas numéricas inferidas por el modelo pertenecen a un espacio latente adimensional. Para que estas predicciones adquieran valor ingenieril y puedan ser interpretadas, comparadas con el límite de referencia (baseline) de la norma ASTM E900-15 y utilizadas para calcular errores térmicos reales, se hace indispensable revertir la transformación matemática.

Para este fin, la clase `RadiationDataset` incorpora el méto-

do personalizado `despreprocess`. Este bloque de código rescata los parámetros de escalado previamente guardados en la memoria del preprocessor (específicamente, `preprocessor.mean_` y `preprocessor.scale_`) localizando dinámicamente el índice correspondiente a la columna objetivo. A continuación, aplica la transformación algebraica inversa sobre las predicciones escaladas (y_{scaled}), proyectándolas de nuevo a su dominio original en grados Celsius:

$$y_{real} = (y_{scaled} \times \sigma_{target}) + \mu_{target} \quad (3.2)$$

Esta arquitectura de preprocesamiento y postprocesamiento garantiza un flujo de información matemáticamente robusto, asegurando que la red neuronal sea alimentada de manera óptima para el aprendizaje.

3.2. Definición del Baseline Físico

En cualquier investigación fundamentada en el desarrollo de arquitecturas de aprendizaje profundo predictivo, resulta metodológicamente imperativo establecer un límite de referencia analítico (conocido en la literatura como *baseline*) antes de proceder al entrenamiento de modelos complejos. En el contexto de la gestión del envejecimiento nuclear,  te punto de referencia no puede ser arbitrario; debe representar el estado del arte normativo actual. Por consiguiente, se ha implementado computacionalmente la norma empírica ASTM E900-15 como métrica de control y

límite base de predicción.

Para materializar este estándar analítico, se ha desarrollado el script `formula.py`, cuyo núcleo computacional reside en la función algorítmica `astm_e900_15`. El propósito de este módulo es ingerir el vector de variables independientes (composición química, temperatura y dosis neutrónica) y proyectarlo sobre las ecuaciones fenomenológicas de la normativa, obteniendo así una predicción puramente determinista sobre el conjunto de prueba.

Desde una perspectiva de ingeniería de software y eficiencia computacional, la formulación matemática de la norma no se ha implementado mediante bucles iterativos tradicionales. En su lugar, se ha procedido a una vectorización completa de las ecuaciones empleando la librería NumPy de Python. La vectorización permite que las operaciones aritméticas se ejecuten en paralelo sobre matrices y tensores de datos completos a nivel de lenguaje C subyacente, acelerando drásticamente el proceso de inferencia y asegurando la escalabilidad del código ante grandes volúmenes de datos de vigilancia.

De acuerdo con la base fenomenológica de la norma ASTM E900-15, la implementación vectorizada calcula el desplazamiento total de la temperatura de transición (ΔTTS) como la superposición aditiva de dos mecanismos de degradación microestructural independientes:

$$\Delta TTS = TTS_1 + TTS_2 \quad (3.3)$$

Donde el término TTS_1 cuantifica el daño en la matriz férrea inducido por la creación de pares de Frenkel y lazos de dislocación (dependiente del fósforo, manganeso y níquel), mientras que el término TTS_2 parametriza el

endurecimiento por precipitación de clústeres ricos en cobre.

Un desafío técnico en la implementación programática de esta ecuación radica en la naturaleza de la variable de entrada `Product_Form`. El comportamiento de la degradación difiere térmicamente si el componente analizado proviene de una soldadura ('W'), de un proceso de forja ('F') o de una placa ('P'). Para integrar esta heurística sin romper la eficiencia de la vectorización matemática, se ha diseñado una lógica de control fundamentada en la función `np.select`.

Esta instrucción permite mapear dinámicamente tensores de variables categóricas hacia sus respectivos multiplicadores numéricos. Específicamente, el código evalúa matrices booleanas concurrentes: si el registro corresponde a soldadura ('W'), el algoritmo asigna un coeficiente de daño base de 0.919; si corresponde a forja ('F'), el coeficiente asciende a 1.011; y para cualquier otro caso normativo (como placa), se asigna un valor por defecto de 1.080. Estos coeficientes actúan como ponderadores directos sobre la ecuación analítica principal, ajustando la severidad de la degradación a la realidad del proceso de manufactura original.

Una vez calculado el tensor de predicciones analíticas, es necesario establecer un marco de evaluación cuantitativo. Para ello, y con vistas a la futura fase de experimentación con redes neuronales, se han seleccionado dos métricas estadísticas fundamentales. En primer lugar, el Error Cuadrático Medio (RMSE, por sus siglas en inglés), el cual penaliza severamente las grandes desviaciones predictivas, otorgando un indicador directo del error en la escala original del problema (grados Celsius). En se-

gundo lugar, el Coeficiente de Determinación (R^2), empleado para cuantificar qué proporción de la varianza en la fragilización térmica es explicada por la norma.

La consecución de esta fase analítica trasciende la mera validación normativa; constituye un anclaje metodológico indispensable. Resulta imposible medir el grado de innovación, robustez y mejora real que aportan las Redes Neuronales Informadas por Física (PINNs) si no se cuenta con un punto de control del error sólidamente establecido. Al fijar el desempeño de la norma ASTM E900-15 como *baseline* físico, se delimita la frontera del conocimiento actual; cualquier reducción del RMSE obtenida posteriormente por los algoritmos de Machine Learning demostrará empíricamente la viabilidad y superioridad del enfoque propuesto en este Trabajo de Fin de Máster para la Operación a Largo Plazo de centrales nucleares.

3.3. Modelos ML no Informados

Para evaluar de forma exhaustiva el rendimiento de las arquitecturas híbridas (PINNs), el diseño experimental de esta investigación exige la construcción previa de un marco comparativo fundamentado exclusivamente en los datos. Por consiguiente, se ha implementado una batería de modelos de control puramente empíricos (*data-driven*) carentes de restricciones fenomenológicas. El propósito de esta fase metodológica es evaluar la capacidad de los algoritmos de Machine Learning tradicionales para capturar las interacciones no lineales entre las variables químicas y neutróni-

cas sin la intervención de sesgos inductivos físicos. Estos modelos base han sido codificados y encapsulados bajo el paradigma de programación orientada a objetos en el módulo `models.py`.

3.3.1. Modelo de Ensamblaje: XGBoost

El primer algoritmo seleccionado para establecer esta línea base algorítmica es un modelo de ensamblaje de árboles de decisión potenciado por gradiente, implementado mediante la clase `BaselineXGBoost`. La elección de XGBoost (*eXtreme Gradient Boosting*) obedece a su contrastada superioridad y robustez en el modelado de datos tabulares heterogéneos, siendo especialmente hábil para descubrir sinergias complejas entre elementos aleantes (como el Cobre y el Níquel) sin requerir que estas interacciones se definan a priori de forma analítica.

El diseño de la clase `BaselineXGBoost` permite una instanciación flexible, aunque parte de un conjunto de hiperparámetros base cuidadosamente seleccionados para controlar la capacidad del modelo y evitar el sobreajuste inicial. Entre estos parámetros destacan:

- `n_estimators`: Define el número total de árboles de decisión (estimadores débiles) que compondrán el ensamblaje secuencial. Un número elevado permite un aprendizaje más profundo de los residuos, pero incrementa el riesgo de memorización del ruido estadístico.
- `max_depth`: Limita la profundidad máxima de cada árbol individual. Al restringir este parámetro, se fuerza al

modelo a aprender patrones generales de fragilización en lugar de reglas hiper-específicas para coladas particulares, actuando como un mecanismo de regularización estructural.

- `learning_rate` (o η): Escala la contribución de cada nuevo árbol al ensamblaje final. Un valor reducido obliga al algoritmo a requerir más estimadores para converger, lo que habitualmente resulta en una generalización más suave y robusta frente a datos no observados.

Para garantizar la reproducibilidad del experimento y facilitar la integración de este modelo en el flujo de inferencia global, se diseñó una metodología de persistencia y serialización alojada en el módulo `utils.py`. Específicamente, la función `save_xgboost_model` se encarga de exportar el estado interno del regresor una vez entrenado. A diferencia de las serializaciones genéricas de Python (como *Pickle*), se optó por guardar la estructura del ensamblaje en formato JSON nativo (`.json`). Esta decisión metodológica asegura la compatibilidad cruzada del modelo guardado, garantizando que el árbol de inferencia pueda ser cargado (`load_xgboost_model`) y auditado en distintos entornos de producción o lenguajes de programación sin dependencias estrictas de la versión de la librería.

3.3.2. Aprendizaje Profundo: Perceptrón Multicapa (MLP Inicial)

El segundo modelo de control empírico pertenece al dominio del aprendizaje pro-

fundo (*Deep Learning*). Se ha implementado una red neuronal artificial, denominada `MLPInicial`, utilizando el *framework* PyTorch. A diferencia del enfoque de partición del espacio del XGBoost, el Perceptrón Multicapa utiliza el Teorema de Aproximación Universal mediante transformaciones geométricas del espacio de características, lo que ofrece un punto de comparación directo a nivel topológico con la futura arquitectura PINN.

El diseño arquitectónico de la red `MLPInicial` se compone de una topología *feed-forward* estándar. El vector de entrada, que agrupa la dosis neutrónica, la temperatura y la composición química, atraviesa una secuencia de capas densamente conectadas (`nn.Linear` en PyTorch). Para permitir que el modelo mapee las dinámicas no lineales de la saturación del daño por radiación, se insertan funciones de activación entre las capas ocultas, evaluándose empíricamente funciones modernas y estabilizadas como ReLU (*Rectified Linear Unit*) o GELU (*Gaussian Error Linear Unit*).

Un aspecto crítico en la ingeniería de datos para esta red fue la transición de las estructuras de datos. Dado que la base de datos se gestiona mediante la clase personalizada `RadiationDataset` (que genera instancias de `Subset` de PyTorch al realizar las particiones de entrenamiento y prueba), se hizo imprescindible desarrollar una rutina de extracción eficiente. Para ello, se implementó la función `subset_to_numpy` en el módulo `dataset.py`. Esta función rastrea el índice real de la variable objetivo (`DT41J_Celsius`) dentro del *DataFrame* original subyacente y desempaqueta los objetos `Subset` en matrices de NumPy pu-

ras (X, y) . Esta transformación actúa como un puente vital, permitiendo que los datos se inyecten de forma transparente y masiva en los tensores computacionales requeridos por el optimizador de la red neuronal.

3.3.3. Minimización del Riesgo Empírico y Justificación Metodológica

El entrenamiento de ambos modelos (tanto el ensamblaje de árboles como la red neuronal profunda) se rige bajo el paradigma clásico de la Minimización del Riesgo Empírico (ERM, por sus siglas en inglés). En esta formulación matemática, la función de pérdida carece absolutamente de cualquier penalización asociada a la física de materiales. El optimizador actualiza los pesos de la red basándose única y exclusivamente en la discrepancia estadística entre el valor de fragilización real (y_i) y el predicho ($\hat{y}_i$).

Para problemas de regresión continua como la estimación del desplazamiento térmico, la formulación matemática minimizada es el Error Cuadrático Medio (MSE):

$$\mathcal{L}_{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (3.4)$$

El diseño de estos modelos desprovistos de conocimiento fenomenológico no es un paso trivial, sino una necesidad epistemológica de la investigación. El modelo físico de la norma ASTM asegura el cumplimiento de las leyes de la termodinámica pero resulta inflexible frente a la dispersión real de los datos. Por el contrario, los modelos *data-driven* descritos en esta sección son universalmente flexibles y logran ajustar la curva con una preci-

sión insuperable en el dominio de interpolación (allí donde la densidad de muestras de entrenamiento es alta).

Sin embargo, el objetivo último de la industria nuclear y de este Trabajo de Fin de Máster es certificar la viabilidad de la Operación a Largo Plazo (LTO). Esto exige predecir el comportamiento del acero a altas fluencias neutrónicas, un régimen operativo donde los datos experimentales históricos son escasos o inexistentes.

Justificando metodológicamente este diseño experimental, la inclusión de estos modelos puramente empíricos servirá para demostrar y evaluar, en el futuro capítulo de Resultados, el grave riesgo de extrapolación (*extrapolation risk*) inherente al Machine Learning clásico. Al carecer de la directriz física de que el daño por radiación debe ser invariablemente monótono y creciente, se espera que modelos guiados exclusivamente por la ecuación matemática $\mathcal{L}_{MSE}$ se ajusten al ruido estadístico local y fallen categóricamente al proyectar predicciones hacia el futuro operativo de la central. Esta validación empírica del colapso de los modelos "no informados" establecerá el argumento definitivo y cuantitativo para justificar la integración de las ecuaciones rectoras en la función de pérdida que definirá a las PINNs en las fases posteriores del estudio.

3.4. Arquitectura del Modelo PINN

El núcleo predictivo y la principal aportación metodológica de este Trabajo de Fin de Máster residen en el diseño, desarrollo e implementación de una Red Neuronal Informada

por la Física (PINN, por sus siglas en inglés). Esta arquitectura trasciende los enfoques puramente empíricos al integrar el conocimiento termodinámico y fenomenológico de la fragilización de materiales directamente en el grafo computacional del aprendizaje profundo. Para materializar este concepto, se ha diseñado la clase `PINNEmbrittlement`, codificada bajo el paradigma de programación orientada a objetos dentro del módulo `models.py` utilizando el *framework* PyTorch.

3.4.1. Diseño Topológico y Dinámico

Desde una perspectiva estructural, la arquitectura base de la red neuronal se sustenta en una topología de tipo perceptrón multicapa de propagación hacia adelante (*feed-forward*). Sin embargo, a diferencia de implementaciones estáticas convencionales, el diseño de la clase `PINNEmbrittlement` ha sido programado de forma estrictamente dinámica.

En el constructor de la clase (`__init__`), la topología de la red no se encuentra codificada de forma rígida (**hardcoded**), sino que se genera iterativamente a través de la clase `nn.Sequential`. El diseño expone hiperparámetros topológicos fundamentales como argumentos de instanciación: la profundidad de la red (mediante el parámetro `num_layers`), la dimensionalidad o anchura de los tensores internos (`hidden_dim`) y la función de activación no lineal a aplicar (`activation`, admitiendo variantes modernas como `nn.SiLU` o `nn.GELU`).

Este enfoque de ingeniería de software dinámico es metodológicamente crucial. Permite que la arquitectura del modelo actúe co-

mo un espacio de hipótesis maleable, facilitando la posterior experimentación automatizada y la optimización de hiperparámetros. El flujo de información comienza recibiendo un vector de entrada estandarizado (compuesto por 7 características químicas y termodinámicas), que atraviesa secuencialmente las transformaciones afines y no lineales definidas, colapsando finalmente en una capa densa de salida lineal unidimensional.

3.4.2. Flujo Tensorial y Estrategia de Aprendizaje Residual

Una de las innovaciones más destacadas de la arquitectura implementada es su estrategia de propagación hacia adelante (*forward pass*). En lugar de obligar a la red neuronal a aprender la física de la fragilización desde cero (un enfoque que requiere grandes cantidades de datos), la clase `PINNEmbrittlement` emplea un enfoque de **modelado híbrido residual**.

El método `forward` se encuentra bifurcado. Por un lado, la red neuronal pura (`self.mlp`) procesa los datos estandarizados para emitir una predicción puramente matemática, denominada residuo neuronal (`nn_residual`). De forma paralela, el modelo cuenta con un bloque analítico integrado (`astm_e900_pytorch`). Dado que las ecuaciones físicas exigen magnitudes en su escala térmica y radiológica original, la arquitectura invoca internamente el método `unscale_inputs`. Este método revierte algebraicamente la transformación *Z-score* de los tensores utilizando las medias y varianzas almacenadas en el preprocesador (`StandardScaler`), aislando hábilmente la

variable objetivo simulada mediante la inyección de un tensor nulo.

Una vez devueltos al espacio físico real, los datos alimentan la versión vectorizada en PyTorch de la norma ASTM E900-15. Finalmente, la predicción analítica resultante (`tts_astm_real`) es normalizada de nuevo al espacio latente y sumada al residuo de la red neuronal.

$$\hat{y}_{total} = \hat{y}_{ASTM(scaled)} + \hat{y}_{residual(MLP)} \quad (3.5)$$

Metodológicamente, esto significa que la PINN no predice la fragilización total, sino que predice la *corrección no lineal* sobre el modelo normativo actual, garantizando que el punto de partida del aprendizaje sea fenomenológicamente correcto.

3.4.3. Motor de Diferenciación Automática (Autograd)

La inyección de restricciones físicas en la red neuronal requiere evaluar cómo cambian las predicciones del modelo ante variaciones en las entradas termodinámicas; específicamente, la derivada de la fragilización respecto a la fluencia neutrónica ($\frac{\partial \hat{y}}{\partial \Phi}$). Para las redes neuronales estándar, los algoritmos de retropropagación (*Backpropagation*) solo calculan gradientes con respecto a los pesos y sesgos internos de las capas.

Para superar esta limitación y convertir la red en una verdadera PINN, se ha introducido un aspecto metodológico clave en el diseño del bucle de entrenamiento: la habilitación explícita del motor de diferenciación automática *Autograd* de PyTorch sobre los datos empíricos. Esto se lo-

gra invocando la instrucción computacional `X_batch.requires_grad_(True)` sobre el tensor de entrada que alimenta a la red en cada iteración (*epoch*).

Al forzar esta directiva, PyTorch construye dinámicamente un grafo computacional acíclico dirigido en la memoria gráfica, registrando cada operación matemática (desde la primera capa lineal hasta el sumatorio residual final) mediante la regla de la cadena del cálculo diferencial. Este grafo latente permite, posteriormente en la función de pérdida (`pinn_loss`), utilizar `torch.autograd.grad` para obtener el gradiente exacto y analítico de la salida respecto a la fluencia neutrónica (columna indexada en `fluence_idx=6`). Sin la activación de este rastreo tensorial desde la matriz de características de entrada, la aplicación de penalizaciones físicas basadas en la monotonía sería matemáticamente irrealizable.

3.4.4. Entorno Computacional y Aceleración de Hardware

La construcción dinámica de grafos computacionales para el cálculo de derivadas de orden superior y el ensamblaje de arquitecturas residuales demandan un elevado coste computacional. Por consiguiente, la metodología experimental ha sido desplegada sobre una infraestructura de alto rendimiento, diseñada explícitamente para el cálculo matricial masivamente paralelo.

Para garantizar la reproducibilidad transplataforma y la estabilidad del sistema frente a largas sesiones de optimización, el ecosistema de investigación se configuró en un entorno de arranque dual (*Dual Boot*) combinando los sistemas operativos Microsoft Windows y Linux

Ubuntu. Esta dualidad permite ejecutar las librerías científicas en entornos UNIX nativos, maximizando la eficiencia en la gestión de memoria y los procesos de recolección de basura (*Garbage Collection*).

A nivel de hardware, los experimentos, la instanciación de los tensores y la optimización de los gradientes físicos se ejecutaron sobre una Unidad de Procesamiento Gráfico (GPU) de arquitectura avanzada NVIDIA RTX 5060. Esta tarjeta fue orquestada a través de un procesador central Intel Core i7 de 12^a generación, apoyado por 32 GB de memoria RAM de alta velocidad para prevenir cuellos de botella en la transferencia perimetral de los *DataLoaders*. La integración entre el modelo de PyTorch y el hardware se realizó mediante la plataforma de computación paralela CUDA (*Compute Unified Device Architecture*), asegurando que tanto las operaciones matriciales de la propagación hacia adelante como el cálculo iterativo del motor *Autograd* se aceleraran en la memoria VRAM, reduciendo el tiempo de convergencia de la arquitectura híbrida a márgenes operativamente viables.

3.5. Función de Pérdida Personalizada

En el paradigma clásico del aprendizaje profundo (*Deep Learning*), el entrenamiento de una red neuronal se rige casi exclusivamente por el principio de Minimización del Riesgo Empírico (ERM). Bajo este marco, el algoritmo de optimización actualiza los parámetros internos del modelo con el único propósito de reducir la discrepancia estadística entre las predicciones y las observaciones empíricas

del conjunto de entrenamiento. Sin embargo, en problemas de ciencia de materiales y seguridad nuclear, donde los datos en regímenes extremos (como las altas fluencias neutrónicas) son escasos, esta dependencia exclusiva de los datos resulta inaceptable. Los modelos puramente empíricos tienden a sobreajustarse al ruido local y, al extrapolar, pueden generar predicciones físicamente absurdas, como sugerir que el acero recupera su tenacidad tras recibir mayores dosis de radiación.

Para solventar esta debilidad estructural, la innovación central de este Trabajo de Fin de Máster radica en la redefinición del problema de optimización mediante el diseño metodológico de una Red Neuronal Informada por la Física (PINN). Esta metamorfosis algorítmica se materializa en la función `pinn_loss` (implementada en el módulo `models.py`), la cual transforma la función de pérdida unidimensional en una función objetivo compuesta, forzando al modelo a aprender no solo de los datos tabulares, sino también de las leyes fundamentales de la termodinámica.

3.5.1. Formulación Matemática de la Pérdida Combinada

El diseño metodológico impone que la red neuronal satisfaga simultáneamente dos criterios de convergencia durante su fase de entrenamiento: el ajuste estadístico a los ensayos de vigilancia y la coherencia termodinámica. Para lograr este balance, se ha diseñado una función de pérdida combinada escalar ($\mathcal{L}_{total}$) que se expresa como la superposición ponderada de dos términos independientes:

$$\mathcal{L}_{total} = \lambda_{data}\mathcal{L}_{data} + \lambda_{mono}\mathcal{L}_{mono} \quad (3.6)$$

El primer término, $\mathcal{L}_{data}$, corresponde a la pérdida puramente empírica evaluada mediante el Error Cuadrático Medio (MSE) sobre el lote de datos (*batch*) actual. Su objetivo es anclar las predicciones del modelo a la realidad experimental histórica. Por su parte, el término $\mathcal{L}_{mono}$ introduce el sesgo inductivo físico.

Los escalares λ_{data} y λ_{mono} actúan como hiperparámetros de regularización e interjuegan un papel crítico en la dinámica de optimización del gradiente descendente. Dado que la topología espacial de la pérdida de datos y la pérdida física pueden presentar curvaturas y órdenes de magnitud drásticamente diferentes, estos coeficientes ponderadores previenen que la restricción termodinámica ahogue el aprendizaje empírico, o viceversa, asegurando una convergencia estable.

3.5.2. La Restricción Física: Monotonía respecto a la Fluencia

A diferencia de otras arquitecturas PINN en la literatura que incorporan Ecuaciones Diferenciales Parciales (PDEs) completas en su función de pérdida, este trabajo adopta un enfoque físico fundamental y altamente robusto: la imposición de la monotonía respecto a la fluencia neutrónica (Φ).

Físicamente, la fragilización por radiación es un proceso de daño acumulativo. El bombardeo neutrónico incesante genera cascadas de colisiones en la red cristalina del hierro, produciendo pares de Frenkel (vacantes e in-

tersticiales) que, asistidos por la temperatura, difunden y se aglomeran formando lazos de dislocación y nano-precipitados ricos en cobre (Cu), níquel (Ni) y manganeso (Mn). Estos defectos actúan como barreras infranqueables para el deslizamiento de las dislocaciones. Por imperativo termodinámico y cinético, un aumento en la dosis de radiación recibida (manteniendo constantes la temperatura y la composición química) solo puede traducirse en una mayor densidad de defectos, y por tanto, en un incremento (o saturación asintótica) del desplazamiento de la temperatura de transición (ΔTTS). Una disminución del daño ante un aumento de radiación viola el segundo principio de la termodinámica en este sistema cerrado.

Por lo tanto, la restricción física exige matemáticamente que la derivada parcial de la predicción de la red neuronal ($\hat{y}$) con respecto a la fluencia neutrónica (Φ) sea estrictamente mayor o igual a cero en todo el dominio del espacio de características:

$$\frac{\partial \hat{y}}{\partial \Phi} \geq 0 \quad (3.7)$$

3.5.3. Algoritmo y Penalización Diferencial Continua

La implementación computacional de este principio requiere calcular la sensibilidad de la salida del modelo respecto a sus variables de entrada sin recurrir a aproximaciones numéricas imprecisas (como diferencias finitas). Para ello, el algoritmo implementado hace uso intensivo del motor de diferenciación automática *Autograd* de PyTorch (`torch.autograd.grad`).

Durante el paso hacia adelante (*forward*

pass), el grafo computacional registra meticulosamente la cadena de operaciones que conectan el tensor de entrada con la predicción escalar $\hat{y}$. Posteriormente, *Autograd* aplica la regla de la cadena (*chain rule*) hacia atrás para obtener la matriz Jacobiana exacta de las salidas respecto a las entradas. Dado que el tensor estandarizado de entrada contiene las características en un orden predefinido, el algoritmo extrae específicamente el gradiente unidimensional correspondiente a la fluencia neutrónica, aislando la columna que ocupa la sexta posición posicional (índice programático `fluence_idx = 6`).

Una vez aislado el vector de derivadas parciales evaluado en las muestras del lote, es necesario construir una función de penalización que solo afecte al modelo cuando se viole la restricción termodinámica. Para lograr esto de forma diferenciable y compatible con los optimizadores basados en momento (como Adam), se ha diseñado una penalización empleando la función de activación de Unidad Lineal Rectificada (ReLU). La ecuación exacta programada en la función `pinn_loss` se formula de la siguiente manera:

$$\mathcal{L}_{mono} = \frac{1}{N} \sum_{i=1}^N \text{ReLU} \left(-\frac{\partial \hat{y}_i}{\partial \Phi_i} \right)^2 \quad (3.8)$$

En esta expresión, el argumento de la función ReLU se define como el gradiente negativo ($-\frac{\partial \hat{y}}{\partial \Phi}$). La elegancia de este diseño algorítmico reside en su respuesta condicional:

- Si la red predice un comportamiento físicamente correcto (el daño aumenta con la radiación, $\frac{\partial \hat{y}}{\partial \Phi} \geq 0$), el argumento invertido se vuelve negativo o cero. La función

ReLU colapsa este valor a 0, de modo que $\mathcal{L}_{mono} = 0$. La red no recibe ninguna penalización y optimiza libremente la pérdida empírica.

- Si, por el contrario, la red empieza a sobreajustarse al ruido y predice una recuperación irreal del material (el daño disminuye, $\frac{\partial \hat{y}}{\partial \Phi} < 0$), el argumento invertido se vuelve positivo. La función ReLU deja pasar este valor. Al elevarlo al cuadrado, se castigan de forma cuadrática y severa las violaciones físicas graves, generando un gradiente corrector inmenso que empuja inmediatamente los pesos de la red de vuelta a la región de soluciones físicamente admisibles.

3.5.4. Justificación Metodológica y Generalización

La adopción de este diseño metodológico trasciende la mera mejora del rendimiento estadístico; constituye una garantía de seguridad computacional. La imposición de la pérdida por monotonía restringe geométricamente el espacio de hipótesis (el conjunto de funciones que la red puede aprender) a un subespacio fenomenológicamente válido.

Esta arquitectura garantiza que, al enfrentar el modelo a escenarios de Operación a Largo Plazo (LTO) de centrales nucleares —donde se requieren proyecciones a 60 u 80 años de vida útil superando los 10^{20} n/cm^2 —, las extrapolaciones serán intrínsecamente conservadoras y seguras. Aunque la red se adentre en un territorio carente de datos experimentales de soporte, la función $\mathcal{L}_{mono}$ impedirá cualquier caída asintótica no lineal, asegurando una pre-

dicción de fragilización que obedece estrictamente al comportamiento dictaminado por la física del estado sólido y la cinética de acumulación de defectos bajo irradiación.

3.6. Optimización de Hiperparámetros

El desarrollo de arquitecturas de aprendizaje profundo y, en particular, de las Redes Neuronales Informadas por la Física (PINNs), exige una configuración arquitectónica sumamente precisa. A diferencia de los modelos empíricos convencionales, las PINNs presentan una superficie de pérdida (*loss landscape*) excepcionalmente compleja debido a la superposición de gradientes contradictorios: aquellos provenientes de la minimización del error de los datos empíricos y los derivados de la restricción termodinámica diferencial. Una configuración subóptima de la red o de los coeficientes de regularización conduce irremediablemente a la divergencia del entrenamiento o a la anulación de la física subyacente. Para abordar este desafío, se ha diseñado e implementado una metodología de optimización automatizada de hiperparámetros (HPO) utilizando el *framework* de optimización Bayesiana Optuna.

3.6.1. Justificación de la Búsqueda Bayesiana

Tradicionalmente, la calibración de modelos se ha realizado mediante búsquedas exhaustivas en cuadrícula (*Grid Search*) o búsquedas aleatorias (*Random Search*). Sin embargo, la evaluación de una PINN requiere

el recálculo constante de grafos computacionales para aislar derivadas físicas durante cientos de épocas, lo que eleva el coste temporal de cada entrenamiento a niveles prohibitivos.

El uso del *framework* Optuna permite superar esta barrera de dimensionalidad. En lugar de explorar el hiperespacio a ciegas, Optuna emplea algoritmos de estimación Bayesiana, concretamente el estimador estructurado de Parzen (TPE, *Tree-structured Parzen Estimator*). Este algoritmo probabilístico modela el rendimiento histórico de las evaluaciones previas (*trials*) para inferir qué regiones del espacio paramétrico tienen mayor probabilidad de albergar la configuración óptima. Metodológicamente, esto garantiza que los recursos computacionales de la GPU se concentren de forma inteligente en las combinaciones de hiperparámetros más prometedoras, descartando tempranamente configuraciones divergentes.

3.6.2. Definición del Espacio de Búsqueda Paramétrico

El diseño experimental requirió la acotación de un hiperespacio de búsqueda (*search space*) riguroso, equilibrando la flexibilidad paramétrica con la tratabilidad computacional. En el código implementado, se definieron cinco familias de hiperparámetros críticos que el algoritmo debía muestrear y optimizar simultáneamente:

- **Topología de la red (`num_layers` y `hidden_dim`):** Se estableció un rango discreto para la profundidad de la red, limitando el número de capas ocultas entre 2 y 3 ($\text{num_layers} \in [2, 3]$). Redes

más profundas corren el riesgo de disipar el gradiente físico. La anchura de los tensores internos se muestreó en un dominio acotado entre 48 y 128 neuronas ($\text{hidden_dim} \in [48, 128]$), permitiendo al modelo escalar su capacidad de aproximación universal según la complejidad de la colada.

- **Funciones de Activación:** Dado que la función de pérdida física exige derivabilidad continua y suave de orden superior para no quebrar el motor *Autograd*, las activaciones estándar como ReLU en las capas ocultas son subóptimas. Por ello, el optimizador iteró categóricamente entre funciones diferenciables avanzadas como SiLU (*Sigmoid Linear Unit*) y GELU (*Gaussian Error Linear Unit*).
- **Tasa de Aprendizaje (`learning_rate`):** Se definió una búsqueda en escala logarítmica (típicamente en el rango de 10^{-4} a 10^{-2}). Esta escala garantiza que Optuna explore equitativamente órdenes de magnitud, un factor crítico dado que el balanceo de gradientes físicos requiere pasos de optimización calibrados.
- **Decaimiento de Pesos (`weight_decay`):** Para evitar el sobreajuste (*overfitting*) a las regiones de baja fluencia donde el dataset presenta mayor densidad de muestras, se incorporó una penalización de regularización L2. Optuna muestreó este valor en un espectro logarítmico para constreñir el crecimiento de los pesos sinápticos.
- **Coeficiente de Regularización Física**

(λ_{mono}): El hiperparámetro metodológicamente más crítico del estudio. Este coeficiente continuo (λ_{mono}) pondera la severidad del castigo termodinámico impuesto en la función de pérdida. Si el valor sugerido por Optuna es excesivo, la red se vuelve dogmática y subajusta los datos; si es defectivo, la PINN degenera en un MLP estándar perdiendo su garantía de seguridad en la extrapolación.

3.6.3. Estrategia de Validación y Función Objetivo

Para garantizar una evaluación estadística insesgada de cada configuración sugerida por Optuna, se implementó una estricta estrategia de aislamiento de datos. Durante el bucle de optimización, el modelo jamás fue expuesto al conjunto de prueba puro (*Test Set*). En su lugar, el algoritmo instanció y entrenó dinámicamente arquitecturas sobre el conjunto de entrenamiento (*Train Set*) y fue evaluado en cada época contra el conjunto de validación (*Validation Set*).

La función objetivo configurada para ser minimizada por Optuna fue el Error Cuadrático Medio de validación (Val-MSE). Para optimizar el tiempo global del estudio, se acopló un mecanismo de *Early Stopping* (detención temprana). Si durante un número predefinido de épocas consecutivas (paciencia) el error de validación de un *trial* específico no lograba crecer, el entrenamiento se interrumpía de manera controlada. El optimizador registraba el mejor error alcanzado y procedía instantáneamente a proponer una nueva arquitectura, mitigando el desperdicio de ciclos de reloj en configuraciones estancadas.

Para asegurar la trazabilidad, persistencia y reproducibilidad del experimento, se configuró el motor de almacenamiento de Optuna sobre una base de datos local SQLite (`pinn_estudio.db`). Esta decisión de ingeniería de software no solo preserva el historial completo del hiperespacio explorado ante posibles fallos de suministro eléctrico, sino que abre la puerta metodológica a paralelizar futuros estudios desplegando múltiples procesos o hilos de GPU que lean y escriban sobre la misma base relacional.

3.6.4. Gestión de Memoria y Aceleración en VRAM

Uno de los cuellos de botella técnicos más severos al optimizar PINNs es la fuga progresiva de memoria (*memory leak*) en las Unidades de Procesamiento Gráfico (GPU). Para computar las derivadas de la monotonía, el motor *Autograd* de PyTorch requiere la bandera `create_graph=True`. Esta instrucción retiene en la memoria VRAM el inmenso árbol de operaciones algebraicas de cada lote para permitir la derivación hacia atrás. A lo largo de múltiples épocas y cientos de *trials* generados por Optuna, estos grafos residuales pueden acumularse, provocando el colapso del sistema por desbordamiento de memoria (*CUDA Out of Memory*).

Para blindar la infraestructura experimental frente a este fallo crítico, se integraron rutinas explícitas de gestión de recursos a nivel de lenguaje. Al finalizar cada *trial* evaluado por Optuna, el diseño de software fuerza la eliminación de las referencias a los tensores locales y de los modelos instanciados, disparando seguidamen-

te el recolector de basura nativo de Python mediante el comando `gc.collect()`. Inmediatamente después, se ordena a la interfaz de aceleración vaciar las memorias en caché retenidas por el controlador de hardware mediante llamadas explícitas (como `torch.cuda.empty_cache()`). Estas decisiones de diseño aseguraron una huella de memoria estable y constante, garantizando la exploración ininterrumpida de cientos de configuraciones arquitectónicas complejas de forma secuencial y desatendida.

Capítulo 4

Resultados y Discusión

El presente capítulo aborda la evaluación cuantitativa y fenomenológica de los modelos desarrollados, contrastando las aproximaciones analíticas normativas con los algoritmos de aprendizaje automático puros y el marco híbrido propuesto basado en Redes Neuronales Informadas por la Física (PINNs). Para simular de manera estricta un escenario de Operación a Largo Plazo (LTO) y evaluar el riesgo de extrapolación, el dataset global de 1889 muestras fue dividido de forma secuencial en función de la fluencia neutrónica (Φ). Se reservó el 75 % de los datos (1416 muestras de bajas y medias fluencias) para el entrenamiento y validación arquitectónica, mientras que el 25 % restante (473 muestras correspondientes a los regímenes de irradiación más elevados y extremos) se aisló por completo como conjunto de prueba (*Test Set*) para validar la robustez del modelo en horizontes temporales extendidos.

4.1. Comparativa Global de Modelos

Para establecer un marco de comparación científica equitativo, se implementó en primera instancia una calibración local del modelo físico de referencia ASTM E900-15 sobre

el conjunto de entrenamiento local mediante el principio de Estimación de Máxima Verosimilitud (MLE), resolviendo un problema de mínimos cuadrados no lineales. Esto permitió ajustar los seis coeficientes multiplicativos globales (A y B para soldaduras, forjas y placas) a la dispersión específica de nuestro banco de datos, obteniendo los parámetros optimizados $A_{weld} = 0,9449$, $B_{weld} = 0,9736$, $A_{forge} = 0,8795$, $B_{forge} = 0,7494$, $A_{plate} = 1,0719$ y $B_{plate} = 0,8541$, dicho ajuste puede verse en la Figura 4.1. La calibración estándar puede observarse en la Figura 4.2 del Anexo.

Los resultados estadísticos globales obtenidos tras la inferencia en el conjunto de prueba ciego se condensan en la Tabla 4.1.

El análisis de la calibración local de la norma ASTM devela un comportamiento característico del sobreajuste en el dominio físico. Al sintonizar de manera óptima los coeficientes fenomenológicos para los datos de baja fluencia, el error en el *Train Set* se contrajo marginalmente de 12,870 °C a 12,815 °C. Sin embargo, al proyectar estas curvas analíticas rígidas hacia el régimen extremo de test, el RMSE se degradó de 15,245 °C a 15,927 °C. Este fenómeno demuestra que las regresiones paramétricas tradicionales, a pesar de su robustez conceptual, carecen de la flexibili-

Modelo Evaluado	RMSE Train (°C)	RMSE Test (°C)	R^2 Test
ASTM E900-15 Estándar (Global)	12.870	15.245	0.8331
ASTM E900-15 Calibrada (Local-MLE)	12.815	15.927	0.8178
XGBoost (<i>Data-driven</i> Puro)	0.3553	64.086	0.1263
PINN Básica (Loss Combinada)	11.579	27.301	–
PINN Extrapolación (Optuna)	11.819	16.240	0.8859

Tabla 4.1: Métricas de rendimiento global en escenarios de extrapolación de alta fluencia (LTO).




Figura 4.1: Ecuación de la norma ASTM E900-15 calibrada localmente mediante el método de Estimación de Máxima Verosimilitud (MLE) sobre el conjunto de entrenamiento. Se observa que, aunque la calibración logra reducir ligeramente el error en el dominio de entrenamiento, la rigidez funcional del modelo normativo impide una mejora significativa en la capacidad de extrapolación hacia regímenes de alta fluencia, evidenciando un comportamiento característico de sobreajuste al dominio físico específico.




Figura 4.2: Ecuación de la norma ASTM E900-15 estandarizada.

4.2. Evaluación en Escenarios LTO (Altas Fluencias)

El hallazgo técnico más crítico de esta investigación radica en el colapso predictivo absoluto manifestado por los algoritmos de Machine Learning tradicionales desprovistos de información física. Tal como se aprecia en la Tabla 4.1 y en la Figura 4.3, el modelo XGBoost óptimo arrojó un RMSE de 64,086 °C en el conjunto de extrapolación. Desde la perspectiva de la ciencia de datos, este comportamiento se atribuye a que el algoritmo de potenciación de gradiente opera segmentando el

dad matemática necesaria para asimilar simultáneamente las variaciones metalúrgicas locales y las tendencias asintóticas globales sin incurrir en distorsiones marginales.

espacio de características mediante hiperplanos ortogonales basados únicamente en la Minimización del Riesgo Empírico ($\mathcal{L}_{MSE}$).

Al adentrarse en regiones de alta fluencia donde la densidad muestral es nula, el modelo decae en aproximaciones geométricas locales que reproducen el ruido estadístico de la frontera de entrenamiento, derivando en trayectorias físicamente imposibles como la pérdida repentina de fragilización o la inversión del signo del daño térmico. En el contexto de la seguridad nuclear, aceptar un margen de incertidumbre superior a los 60 °C invalidaría por completo cualquier análisis de choque térmico presurizado (PTS).




Figura 4.3: Comparativa del Error Cuadrático Medio (RMSE) en grados Celsius para los distintos modelos, evaluado sobre el conjunto de extrapolación (25 % superior de fluencias neutrónicas). Se evidencia el severo colapso predictivo del modelo data-driven puro (XGBoost) en escenarios simulados de Operación a Largo Plazo (LTO). En contraste, las arquitecturas híbridas (PINN) logran corregir esta divergencia mediante la imposición del sesgo inductivo de monotonía, mitigando el riesgo de extrapolación y alcanzando un rendimiento competitivo frente al baseline analítico normativo (ASTM E900-15)

Por el contrario, la introducción del sesgo

inductivo termodinámico mediante la función de pérdida por monotonía modificó sustancialmente la topografía de optimización. La PINN Básica logró reducir el error de extrapolación de Machine Learning a más de la mitad, registrando un RMSE de 27,301 °C. Tras someter el grafo computacional híbrido a una optimización Bayesiana exhaustiva mediante Optuna, la denominada PINN Extrapolación alcanzó un RMSE definitivo de 16,240 °C, elevando el coeficiente de determinación (R^2) hasta un destacado 0.8859.

Esto implica que el modelo propuesto no solo corrige las desviaciones no físicas del Machine Learning puro, sino que se sitúa a una distancia menor a 0,3 °C del rendimiento de la norma analítica óptima local (15,927 °C). La PINN actúa así como un interpolador estadístico de alta fidelidad para composiciones químicas específicas dentro del dominio conocido y como un extrapolador seguro y físicamente consistente guiado por la directriz monótona de la física del estado sólido en regímenes extendidos.

4.3. Discusión

La convergencia exitosa del modelo computacional híbrido dependió estrictamente de las interacciones dinámicas de su arquitectura profunda descubiertas en la fase de optimización automatizada. El estudio Bayesiano determinó que el diseño óptimo (alcanzado en el *Trial* 20) requería una topología compuesta por un extractor de características denso de 3 capas ocultas con una dimensión interna constante de 96 neuronas, operado bajo una tasa de aprendizaje de 0,00395 y una regularización L2 ('weight_decay') restrictiva de $9,70 \times 10^{-5}$.

Metodológicamente, se constató que la selección de la función de activación desempeña un rol fundamental en la viabilidad matemática de las PINNs. Mientras que los Perceptrones Multicapa tradicionales emplean la función ReLU debido a su simplicidad computacional, las PINNs exigen funciones de activación de suavizado continuo como **GELU** o **SiLU**. Dado que la restricción física se evalúa inyectando el residuo diferencial continuo mediante el motor *Autograd* ($\mathcal{L}_{mono} \propto \text{ReLU}(-\frac{\partial \hat{y}}{\partial \Phi})^2$), el uso de ReLU convencional—cuya segunda derivada es nula o indefinida en el origen— interrumpe el flujo hacia atrás del gradiente de orden superior, provocando la desconexión de la componente física del entrenamiento. Las activaciones como GELU preservan la curvatura matemática del espacio latente, permitiendo que la penalización por monotonía actúe como un regularizador geométrico continuo sobre los pesos sinápticos.

Finalmente, el comportamiento del hiperparámetro de ponderación física ($\lambda_{mono} = 0,9387$) evidenció la naturaleza del compromiso multiobjetivo del problema. Durante las iteraciones experimentales, valores excesivamente bajos de $\lambda_{mono} (\leq 0,1)$ provocaban que la red mutara instantáneamente hacia un Perceptrón convencional, exhibiendo una excelente precisión local pero divergiendo drásticamente hacia pendientes negativas en altas fluencias.

Por otro lado, valores sobredimensionados de la fuerza física ($\lambda_{mono} \geq 2,0$) forzaban al optimizador Adam a priorizar el residuo diferencial sobre el error empírico, convirtiendo a la red en un clon rígido y dogmático de la ecuación ASTM que subajustaba la variabili-

dad química real de las probetas Charpy. El valor balanceado de $\approx 0,94$ hallado por Optuna garantizó el equilibrio exacto: la flexibilidad estadística para mapear las complejas interacciones no lineales del cobre, níquel y manganeso, constreñida bajo el límite infranqueable de la segunda ley de la termodinámica.

Capítulo 5

Conclusiones y Trabajo Futuro

El desarrollo, implementación y validación del marco predictivo híbrido presentado en este Trabajo de Fin de Máster permiten extraer conclusiones de gran relevancia científica y tecnológica para el ámbito de la seguridad nuclear y el diseño de algoritmos avanzados de aprendizaje computacional. En primera instancia, se ha comprobado empíricamente el colapso predictivo absoluto que sufren los modelos tradicionales dirigidos exclusivamente por datos (*data-driven*), como XGBoost, al adentrarse en regímenes de alta fluencia neutrónica no observados durante el entrenamiento. Al alcanzar un RMSE inasumible de 64,086 °C en el conjunto de prueba, queda demostrado que la Minimización del Riesgo Empírico clásica es inherentemente incapaz de asimilar criterios de coherencia fenomenológica, priorizando el ajuste del ruido estadístico local por encima de las leyes de la termodinámica y divergiendo hacia trayectorias físicamente imposibles en el dominio de extrapolación.

Por el contrario, la integración de Redes Neuronales Informadas por la Física (PINNs) se erige como una metodología robusta y viable para certificar la Operación a Largo Plazo (LTO) de las centrales nucleares. Al restringir el espacio de hipótesis de la red mediante una penalización diferencial, la arquitectura híbri-

da redujo de manera drástica el error de extrapolación del Machine Learning puro, consolidando un RMSE definitivo de 16,240 °C y un coeficiente de determinación R^2 de 0.8859 en el conjunto de prueba ciego de altas fluencias. Esta notable reducción del error sitúa al modelo propuesto en un rendimiento prácticamente idéntico al de la norma analítica óptima local, con la ventaja añadida de retener la flexibilidad geométrica del cálculo neuronal para capturar las interacciones no lineales de los elementos aleantes dentro del dominio conocido.

Asimismo, la investigación demuestra la extraordinaria eficacia del sesgo inductivo de monotonía aplicado al problema de la degradación de materiales. La imposición de la restricción matemática que exige que la derivada parcial de la predicción respecto a la fluencia sea estrictamente mayor o igual a cero, evaluada mediante el motor de diferenciación automática *Autograd* de PyTorch, demostró ser suficiente para guiar al modelo en ausencia de datos experimentales de soporte. Esta directriz impide que el Perceptrón Multicapa proyecte recuperaciones irrealistas de tenacidad, forzando trayectorias asintóticas estables y consistentes con la cinética de acumulación de defectos y nano-precipitados en la matriz del

acero ferrítico.

Finalmente, se ha determinado que la convergencia exitosa de este tipo de arquitecturas híbridas depende críticamente de una cuidadosa sinergia entre la topología de la red, sus funciones de transferencia y el equilibrio de la función de pérdida. El uso de activaciones de suavizado continuo como SiLU o GELU resulta matemáticamente imperativo para preservar el flujo del gradiente de orden superior, evitando la desactivación del término físico que ocurre al emplear la función ReLU convencional. De igual forma, el marco de optimización automatizada Optuna resolvió con éxito el complejo compromiso multiobjetivo del espacio latente, hallando el peso exacto de la componente física ($\lambda_{mono} \approx 0,94$) necesario para hibridar con éxito la expresividad estadística y el rigor normativo de la norma ASTM E900-15.

A partir de las bases metodológicas y los resultados establecidos en esta investigación, se vislumbran diversas líneas de desarrollo futuro orientadas a expandir el alcance, la robustez y las capacidades operativas del modelo híbrido desarrollado. Una primera vía de expansión consiste en la incorporación de restricciones físicas multidimensionales en la función de pérdida compuesta. Si bien la monotonía respecto a la fluencia ha demostrado una gran solvencia, futuras iteraciones del modelo podrían integrar penalizaciones basadas en inecuaciones diferenciales asociadas a la cinética termodinámica de difusión de solutos. Imponer restricciones de convexidad o límites de saturación específicos respecto a la temperatura de irradiación o la concentración de elementos clave como el cobre, el níquel y el manganeso robustecería el comportamiento del modelo ante composiciones químicas extremas o cola-

das metalúrgicas atípicas.

En el ámbito de la seguridad nuclear, proporcionar una predicción puntual del desplazamiento de la temperatura de transición (TTS) resulta insuficiente para una toma de decisiones plenamente informada. Por ello, se plantea como línea prioritaria la hibridación de esta arquitectura con técnicas de cuantificación de la incertidumbre, tales como las Redes Neuronales Bayesianas (BNNs) o enfoques de *Monte Carlo Dropout*. Esto permitiría asociar intervalos de confianza epistémica y aleatoria a las extrapolaciones de alta fluencia. De este modo, se ofrecería a los organismos reguladores una métrica probabilística rigurosa del riesgo de fallo por choque térmico presurizado (PTS), transformando el modelo en una herramienta de diagnóstico conservadora y alineada con los estándares de la industria.

Asimismo, se propone explorar la generalización trans-operativa del modelo mediante la inyección de registros procedentes de reactores de tecnologías diversas, como los diseños avanzados de agua a presión VVER o los futuros sistemas de Generación IV. Para abordar la heterogeneidad de estas bases de datos, el uso de Redes Neuronales de Grafos (GNNs) permitiría mapear las estructuras cristal-químicas de las diferentes forjas y soldaduras de manera directa, reemplazando las variables categóricas simples por descriptores metalúrgicos continuos. Esto potenciaría la capacidad de transferencia de la red, permitiendo exportar el conocimiento físico adquirido hacia nuevos materiales sin perder las garantías de seguridad en la extrapolación.

Por último, el objetivo de transferencia tecnológica definitivo de este trabajo se orienta hacia el despliegue del grafo computacio-

nal optimizado en una plataforma de *software* industrial enfocada en el desarrollo de Gemelos Digitales (*Digital Twins*) para centrales en operación activa. Esta integración permitiría monitorizar en tiempo real el historial acumulado de fluencia de una vasija específica a partir de los datos de los sensores del reactor. Gracias a las garantías de extrapolación segura de la PINN, el sistema sería capaz de proyectar con precisión cuántos años de operación segura restan antes de comprometer los límites de integridad estructural, optimizando los ciclos de mantenimiento y garantizando la viabilidad de la explotación energética a largo plazo de forma científicamente defendible.

Bibliografía

- Bonny, G., Terentyev, D., & Bakaev, A. (2013). Ab initio based modelling of dislocation mobility in Fe-Cu alloys. *Journal of Nuclear Materials*, 433, 324-331.
- D'Agata, E., et al. (2025). The LYRA-10 Experiment: Irradiation of Light Water Reactor Pressure Vessel Steels... *Nuclear Science and Engineering*, 1-17.
- Eason, E. D., Odette, G. R., & Nanstad, R. K. (2013). Attenuation of radiation damage in reactor pressure vessel steels. *ASTM Special Technical Publication*, 1559, 1-20.
- Karniadakis, G. E., Kevrekidis, I. G., Lu, L., Perdikaris, P., Wang, S., & Yang, L. (2021). Physics-informed machine learning. *Nature Reviews Physics*, 3(6), 422-440.
- Liu, Y.-c., Wu, H., Mayeshiba, T., Afflerbach, B., Jacobs, R., Perry, J., George, J., Cordell, J., Xia, J., Yuan, H., et al. (2022). Machine learning predictions of irradiation embrittlement in reactor pressure vessel steels. *npj Computational Materials*, 8(1), 85. <https://doi.org/10.1038/s41524-022-00760-4>
- Ma, T., et al. (2020). Deep learning for accelerated discovery of high-entropy alloys. *Materials Today*, 38, 85-93.
- Mathew, J., Parfitt, D., Riddle, N., & Chard-Tuckey, P. (2018). Reactor pressure vessel embrittlement: Insights from neural network modelling. *Journal of Nuclear Materials*, 502, 311-322.
- Odette, G. R., Nanstad, R. K., Server, W. L., & Eason, E. D. (2019). On the history and status of reactor pressure vessel steel ductile to brittle transition temperature shift prediction models. *Journal of Nuclear Materials*, 526, 151863.
- Pang, G., Lu, L., & Karniadakis, G. E. (2020). fPINNs: Fractional physics-informed neural networks. *SIAM Journal on Scientific Computing*, 42(4), A2603-A2630.
- Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378, 686-707.